### پروژه کارشناسی

## مقدمهای بر کلان دادهها

نام و نام خانوادگی دانشجو

سعید عطایی

شماره دانشجویی

971744-1--

استاد پروژه

سركار خانم دكتر انسان

استاد داور

جناب دکتر سوادی

#### چکیده:

بیگ دیتا یا کلان داده چند سالیست که در ادبیات فناوری اطلاعات به یک اصطلاح فراگیر تبدیل شده است. معمولا، کلان دادهها به مجموعه دادههایی گفته می شود که توانایی دریافت، اکتساب، مدیریت و پردازش آنها در یک زمان قابل قبول به وسیله فناوری اطلاعات و ابزارهای نرمافزاری و سختافزاری سنتی وجود ندارد. عبارت Big Data مدتها است که برای اشاره به حجمهای عظیمی از دادهها که توسط سازمانهای بزرگی مانند گوگل یا ناسا ذخیره و تحلیل می شوند مورد استفاده قرار می گیرد. اما به تازگی، این عبارت بیشتر برای اشاره به مجموعههای دادهای بزرگی استفاده می شود که رشد فزاینده ی میزان دادهها به حدی است که با ابزارهای مدیریتی و پایگاههای داده سنتی و معمولی قابل مدیریت نیستند. مشکلات اصلی در کار با این نوع دادهها مربوط به برداشت و جمعآوری، ذخیره سازی، جست وجو، اشتراک گذاری، تحلیل و نمایش آنها است. این مبحث، به این دلیل هر روز جذابیت و مقبولیت بیشتری پیدا می کند که با استفاده از تحلیل حجمهای بیشتری از دادهها، می توان تحلیلهای بهتر و پیشرفته تری را برای مقاصد مختلف، از جمله مقاصد تجاری، پزشکی و امنیتی انجام داد و نتایج مناسب تری را دریافت کرد. تحقیقات در زمینه ی کلان دادهها باید روی چگونگی استخراج ارزش آنها، چگونگی استفاده از دادهها و چگونگی تبدیل آنها از گروهی از دادهها به کلان دادهها تمرکز کنند.

هدوپ یک فریمورک متن باز برای ذخیرهسازی امن و پردازش توزیع شده دادههای حجیم میباشد که دارای دو بخش اصلی سیستم فایل توزیع شده هدوپ و موتور پردازش نگاشت و کاهش میباشد. ساختار هدوپ برای کار با دادههای بزرگ طراحی شده است. لذا زمانی که ما دارای فایلهای کوچک کلان هستیم، هدوپ نمی تواند برخورد مناسبی در مواجه با این مساله از خود نشان دهد و باعث ایجاد بار سنگین بر روی گره اصلی هدوپ و افزایش زمان پردازش نگاشت و کاهش میشود. راهکارهای متفاوتی می تواند در برخورد با دادههای کوچک به کار برده شود تا باعث بهبود عملکرد ذخیره سازی و پردازش و محاسبات هدوپ شود.

#### فهرست محتوا

1	فصل ۱
١	فصل ۱
۲	١-اتعريف
٣	۲-اویژگی ها
٥	۳-۱انواع داده ها
٦	۴-۱کاربرد ها
Υ	۵-۱چالش ها
Υ	۶-۱صنایعی که از کلان داده ها استفاده می کنند
٩	فصل ۲
٩	پایگاه دادههای NoSQL
1.	١-٢مقدمه
	۲-۲مدلهای دادهای در پایگاه دادههای غیر رابطهای
	۳-۲معیارهای گزینش پایگاه داده NoSQL
18	فصل ۳
18	ساز گاری دادهها در پایگاهدادههای غیررابطهای
	۱-۳تئوری CAP
	۲-۳ویژگیهای ACID و BASE
74	فصل ۴
	ماشین مجازی
	١-۴معرفي
	ر ت ۲-۴آموزش نصب
	فصل ۵فصل م
	ى داكر-DOCKER DOCKER
	۱-۵ معرفی
	۱–۵ معرفی
	١-۵ تعاوت آن با ماسين مجاري

فص
اً پا
فص
طر
فص
اکو

77	۴-۸ آپاچی ماهوت APACHE MAHOUT
٦٤	۵-۸ آپاچی زو کیپر – APACHE ZOOKEEPER
۶۵	فصل ۹
۶۵	آپاچی هایو   Apache Hive
٦٦	١–٩ معرفي
٦٧	۲-۹ نصب آپاچی Hive بر روی اوبونتو
۶۹	فصل ۱۰
۶۹	آپاچی اسپارک  APACHE SPARK
٧٠	١١ معرفي
٧١	۲-۱۰ نصب آپاچی اسپارک بر روی اوبونتو
٧٣	۳-۱۰ اجرای مثال WordCount
٧۵	فصل ۱۱
٧۵	آپاچی اچبیس  APACHE HBASE
٧٦	١-١١ معرفي
٧٦	۲–۱۱ نصب آپاچی hbase بر روی اوبونتو
٧٩	منابع و ماخذ

#### فهرست شكل ها

۲	1-	شکل ۱
Ψ	١-٠	شکل ۲
۴	1-	شکل۳-
۴	1-	شکل ۴
17	۲-	شکل ۱
١٨	٣-	شکل ۱
١٨	٣-'	شکل ۲
YY	۰-۳-۰	شکل ۳
۲۵	۴- ۴-	شکل ۱
79	۴-۱ ۴-۱	شکل ۲
۲۷	۴-۱ ۴-۱	شکل ۳
۲۷	۴-۰ ۴-۰	شکل ۴
۲۸	۴-۵	شکل ۵
۲۸	········ ۴-;	شکل ۶
۲۹	۴-۱	شکل ۷
٣٠	۵-	شکل ۱
٣٢	۰-۵-۰۰	شکل ۲
٣٣	۱-۵	شکل ۳
٣۶	۰-۵	شکل ۴
٣۶	Δ-α	شکل ۵
٣٧	Δ-;	شکل ۶
٣٧	۰-۵	شکل ۷
۴١	<i>9</i> -	شکل ۱
۴۲	۰ ۶-۱	شکل ۲
۴٣	۰-۶	شکل ۳
۵۳	γ-	شکل ۱
۵۵	Y-'	شکل ۲
۵۵	Y-Y	شکل ۳
۵٧	Y-'	شکل ۴
۵۹		
۶٠		_
۶۱		

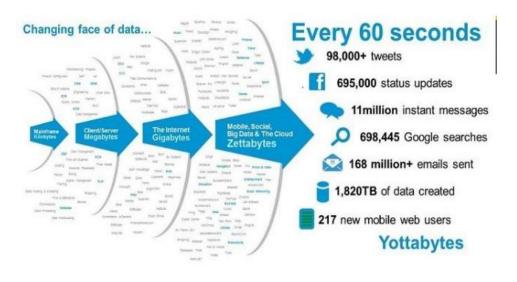
۶۲	شکل ۴-۸
۶۳	شکل ۵-۸
<i>5</i> ¥	شكل ۶-۸
99	شکل ۱-۹
γ	شكل ١٠-١
Υ1	شکل ۲-۲۰
Y1	شکل ۳-۱۰
٧٢	شکل ۴-۱۰
٧٣	شکل ۵-۱۰
٧۴	شكل ۶-۱۰
٧۵	شکل ۱۱-۱
٧٨	شکل ۱۱-۲
٧٨	شکا , ۳-۱۱

فصل ۱

# کلان داده

عبارت Big Data مدتها است که برای اشاره به حجمهای عظیمی از دادهها که توسط سازمانهای بزرگی مانند گوگل یا ناسا ذخیره و تحلیل میشوند مورد استفاده قرار میگیرد؛ اما به تازگی، این عبارت بیشتر برای اشاره به مجموعههای دادهای بزرگی استفاده میشود که بهقدری بزرگ و حجیم هستند که با ابزارهای مدیریتی و پایگاههای داده سنتی و معمولی قابل مدیریت نیستند. مشکلات اصلی در کار با این نوع دادهها مربوط به برداشت و جمعآوری، ذخیرهسازی، جستوجو، اشتراکگذاری، تحلیل و نمایش آنها است.

این مبحث، به این دلیل هر روز جذابیت و مقبولیت بیشتری پیدا می کند که با استفاده از تحلیل حجمهای بیشتری از دادهها، می توان تحلیلهای بهتر و پیشرفته تری را برای مقاصد مختلف، از جمله مقاصد تجاری، پزشکی و امنیتی، انجام داد و نتایج مناسب تری را دریافت کرد. بیشتر تحلیلهای مورد نیاز در پردازش دادههای عظیم، توسط دانشمندان در علومی مانند هواشناسی، ژنتیک، شبیه سازی های پیچیده فیزیک، تحقیقات زیست شناسی و محیطی، جست وجوی اینترنت، تحلیلهای اقتصادی و مالی و تجاری مورد استفاده قرار می گیرد. حجم دادههای ذخیره شده در مجموعههای دادهای Big تحلیلهای اقتصادی و مالی و تجاری مورد استفاده قرار می گیرد. حجم دادههای ذخیره شده در مجموعههای موبایل، کمولی موبایل، شبکههای موبایل، و بیشرهای محیطی، لاگ نرم افزارهای مختلف، دوربینها، میکروفونها، دستگاههای تشخیص RFID، شبکههای حسگرهای محیطی، با سرعت خیره کننده ای در حال افزایش است.

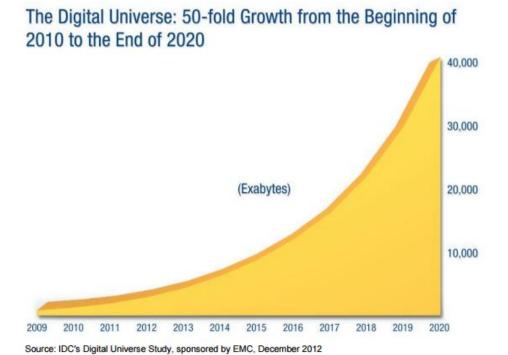


شکل ۱-۱

#### ۱-۲ ویژگی ها

معمولا کلان داده را همراه با خصوصیات آن معرفی می کنند. پژوهشگران، سازمانها و افراد فعال در حوزه کلان داده ویژگیهای متفاوتی از کلان داده ارائه دادهاند. برای مثال موسسه گارتنر سه ویژگی حجم، نرخ تولید و تنوع را به عنوان خصوصیات محیط کلان داده معرفی می کند. شرکت IBM علاوه بر این سه خصوصیت، صحت را نیز به عنوان یکی دیگر از خصوصیات محیط کلان داده معرفی کرده است. و یا در تعریفی دیگر علاوه بر خصوصیات بالا از ارزش نیز به عنوان یکی از ابعاد کلان داده میشود. شرکت مایکروسافت هم ۶ ویژگیهای حجم، تنوع، نرخ تولید، صحت، تغییر پذیری و قابل نمایان بودن دادهها را نیز به عنوان خصوصیات محیط کلان داده معرفی کرده است. هریک از این ویژگیها بعد جدیدی از دنیای کلان داده را برای ما مشخص می کند. ما در اینجا در مورد پنج ویژگی حجم، نرخ تولید، تنوع، صحت و ارزش دادهها صحبت خواهیم کرد:

حجم: منظور از حجم "اندازه دادهها" میباشد، که با سرعت فزایندهای روز به روز در حال گسترش است. اندازه ی دادههایی که توسط انسانها، ماشینها و تعامل آنها در رسانههای اجتماعی تولید میشود، به تنهایی بسیار بزرگ است. پژوهشگران پیش بینی کردهاند که تا سال ۲۰۲۰، ۴۰ زتابایت (۴۰۰۰۰ اگزابایت) داده تولید خواهد شد، که نسبت به سال ۲۰۰۵، ۲۰۰ برابر افزایش خواهد داشت.



شکل ۲-۱

نرخ تولید: منظور از نرخ تولید، میزان سرعتی است که منابع مختلف بهطور روزانه، داده تولید می کنند. این حجم از جریانِ داده بسیار عظیم بوده و پیوسته در حال تولید است. در حال حاضر ۱۰۰۳ میلیارد "کاربرِ فعالِ روزانه" فیسبوک وجود دارند که از موبایل استفاده می کنند و سالانه ۲۲٪ نیز افزایش می یابند. این آمار نشان می دهد که تعداد کاربران رسانه های اجتماعی با چه سرعتی در حال افزایش است و روزانه داده ها با چه سرعتی تولید می شوند. چنان چه بتوانید این میزان از نرخ تولید را مدیریت کنید، به شناختی خواهید رسید که قادر خواهید بود بر پایه ی داده های زمان واقعی تصمیماتی اتخاذ کنید.

تنوع: از آنجایی که منابع فراوانی وجود دارند که می توانند به عنوان دادههای اولیه در راه حلهای کلان داده مورد تحلیل قرار بگیرند، قاعدتاً نوع دادههایی که ایجاد می شود نیز متفاوت است. این دادهها می توانند ساختاریافته، نیمه ساختیافته و یا بدون ساختار باشند. از این رو، با تنوع دادههای متعددی مواجه هستیم که روزانه تولید می گردند. پیش از این، معمولا اکثریت دادهها در قالبهای ساختاریافته وجود داشتند، اما همان طور که در تصویر پایین نشان داده شده است، امروزه دادههایی به شکل تصاویر، فایلهای صوتی، ویدئو، دادههای حس گر و غیره وجود دارند. به همین سبب، این تنوع داده، چالشهای جدیدی در دریافت، ثبت، ذخیره سازی، تجزیه و تحلیل داده ها بوجود آورده است.



شکل۳-۱

صحت: منظور از صحت، دادههایی است که به دلیل ناسازگاری و عدم یکپارچگی در میان آنها، موجب شک و تردیدی در دادههای موجود می شود. در تصویر پایین، مشاهده می کنید که مقادیر اندکی در این جدول از دست رفته است. همچنین پذیرفتن بعضی از مقدارها هم سخت است، برای مثال – عدد ۱۵۰۰۰ در ردیف سوم، که حداقل مقدار را نشان می دهد، غیر ممکن به نظر می رسد. این ناسازگاری و غیر یکپارچگیها، همان صحت دادهها می باشد.

Min	Мах	Mean	SD
4.3	?	5.84	0.83
2.0	4.4	3.05	5000000
15000	7.9	1.20	0.43
0.1	2.5	?	0.76

شکل ۱-۴

گاهی اوقات ممکن است دادههای موجود، نامرتب باشند و شاید اطمینان کردن به آنها دشوار شود. با وجود آشکال مختلفی که کلان داده دارند، کنترل و نظارت بر کیفیت و صحت دادهها سخت می شود، مانند پستهای توییتر که با هشتگ، مخفف، غلطهای املایی و زبان محاوره نوشته می شوند. اغلب اوقات دلیل این عدم کیفیت و صحت دادهها، حجم بسیار انبوه دادهها است که از طریق راههای سنتی امکان تطابق و بررسی صحت آنها وجود ندارد.

ارزش: پس از بررسی حجم، نرخ تولید، تنوع و صحت، به خصوصیت ارزش در تعریف کلان داده میپردازیم. دسترسی به دادههای عظیم بسیار ارزشمند است، اما چنانچه نتوانیم این دادهها را ارزشگذاری کنیم، آنها بلااستفاده باقی میمانند. حال اگر این دادهها به ارزشی که مد نظر ما است برسد، آیا برای سازمانهایی که این دادهها را تجزیه و تحلیل می کنند، مفید واقع خواهند شد؟ آیا سازمانهایی که بر روی کلان داده فعالیت می کنند، بازگشت سرمایهی (ROI) چشم گیری خواهند داشت؟ در نهایت باید گفت چنانچه کار کردن بر روی کلان داده نتواند سودآوری لازم را داشته باشد، برای سازمانها بی فایده خواهد بود.

۱-۳ انواع داده ها

دادههای موجود در دنیای امروز را می توان به ۳ بخش تقسیم کرد:

دادههای ساختاریافته: دادهها می توانند در فرمت ثابتی که "دادههای ساختاریافته" نامیده می شوند، ذخیره و پردازش شوند. یک نمونه از دادههای ساختاریافته، دادههایی هستند که در سیستم مدیریت پایگاه داده رابطهای (RDBMS)، ذخیره می شوند. پردازش دادههای ساختاریافته آسان است، چرا که این نوع دادهها دارای شِمای ثابتی هستند. اغلب اوقات از زبان پرس و جوی SQL برای مدیریت این نوع دادهها استفاده می شود.

دادههای نیمه ساختیافته: دادههای نیمه ساختیافته، دادههایی هستند که ساختار رسمی "مدل داده" را ندارند، یعنی فاقد تعریف جدول در یک پایگاه داده رابطهای هستند. با این وجود، این نوع دادهها از برخی ویژگیهای سازمانی، همچون تگها و برخی نشان گذارهای دیگر که برای جدا کردن عناصر معنایی، که تجزیه و تحلیل دادهها را ساده تر می کند، بهره میبرند. فرمتهای داده XML و مستندات JSON دو نوع از متداول ترین دادههای نمیه ساختاریافته هستند

دادههای بدون ساختار: دادههایی هستند که شکل و ساختاری مشخصی ندارند و به همین جهت RDBMSها راهحل مناسبی برای ذخیره، تجزیه و تحلیل این دادهها نیستند. فایلهای متنی و محتویات چندرسانهای همچون تصاویر، فایلهای صوتی و ویدئوها، نمونههایی از دادههای بدون ساختار هستند. سرعت رشد دادههای بدون ساختار بیشتر از دیگر دادهها است

و طبق نظر کارشناسان ٪۸۰ دادههای یک سازمان، بدون ساختار هستند. پایگاه دادههای غیر رابطهایی(NoSql) یکی از دسته ابزارهایی هستند که میتوانند برای ذخیره و پردازش این نوع از دادهها بکار روند.

۱-۴ کاربرد ها

یکی از مهم ترین کار کردهای فناوری های Big Data، افزایش ضریب هوشمندی بنگاههای اقتصادی است. این فناوریها بعد از تغذیه، گردآوری و پردازش دادهها، اقدام به تحلیلهای هوشمند داده-ها با هدف بهرهبرداری در هوش تجاری (هوشمندی کسبوکار) سازمان، داده کاوی و یادگیری ماشین، می کنند. این موارد می توانند سازمانها، سیستمهای اطلاعاتی و تصمیمات آن را با شرایط پیرامونی تطبیق پذیر (Adaptive) و پیشدستانه (Proactive) نماید.

امروزه تقریباً همهی صنایع، از کاربردهای کلان داده به یک یا چند شیوه بهره میبرند.

**مراقبتهای بهداشتی هوشمند**: با تکیه بر دادههای مربوط به بیماران، سازمانها میتوانند اطلاعات مفیدی را استخراج کند و اپلیکیشنهایی بسازند که میتواند پیشاپیش اوضاع بیمار را پیش بینی کند.

مخابرات: بخشهای مخابراتی اطلاعات را جمع آوری و آنها را تجزیه و تحلیل می کنند و راه حلهایی برای مشکلات مختلف ارائه می دهند. به عنوان یکی از کاربردهای کلان داده، شرکتهای مخابراتی قادر هستند به طور چشم گیری، از دست رفتن بسته می در نتیجه می توانند ارتباطی بسته ما در سطح شبکه که در زمانهای پر ترافیک در شبکه اتفاق می افتد را کاهش دهند، در نتیجه می توانند ارتباطی یک پارچه برای مشتری هایشان فراهم آورند.

خرده فروشی [آنلاین]: بازار خرده فروشی ارتباط تنگاتنگی با کلان داده دارد و یکی از بزرگترین ذینفعهای کلان داده میباشد. زیبایی استفاده از کلان داده در خرده فروشی، درک رفتار مشتری است. موتور توصیهی آمازون، پیشنهاداتی بر اساس تاریخچه مرورگر مشتری، ارائه میدهد.

**کنترل ترافیک**: تراکم ترافیک، چالشی بزرگ برای بسیاری از شهرها در سرتاسر جهان است. استفاده ی بهینه از دادهها و حس گرها، نکته ای کلیدی در کنترل هر چه بهتر ترافیک است، چراکه جمعیت شهرها به سرعت در حال افزایش است. سرعت پردازش دادهها، حجم تولید شده و همچنین تنوع دادهها بخوبی در این موردکاری قابل حس هستند.

**کیفیت جستجو**: هر زمان که اطلاعاتی را از گوگل استخراج میکنیم، همزمان در حال ایجاد دادههایی برای گوگل هستیم. گوگل این دادهها را ذخیره میکند و از آن برای بهبود بخشیدن به کیفیت جستجو استفاده میکند.

#### ۱-۵ چالش ها

**کیفیت دادهها** – بررسی کیفیت دادهها یکی از چالشهای مهم در بحث کلان داده میباشد. مشکلی که در این مبحث مطرح میشود، به عامل "صحت" دادهها باز می گردد. معمولا دادهها نامنظم، ناسازگار و غیر یکپارچه هستند و قبل از هر گونه تحلیل نیاز به مراحلی برای بررسی کیفیت داده دارند.

کشف- رسیدن به یک بینش و شناخت در زمینهی کلان داده، مانند پیدا کردن سوزن در انبار کاه است. تجزیه و تحلیل دادهها در مقیاس پتابایت، با استفاده از الگوریتمهای بسیار قدرتمند، به منظور یافتن الگوها و شناخت آن دادهها، بسیار دشوار است.

ذخیره سازی – هرچه مقدار دادهها در یک سازمان بیشتر باشد، متعاقباً مشکلاتی که برای مدیریت آن دادهها پیش می آید، پیچیده تر می شود. در راه حلهای کلان داده یکی از سوالات اساسی این است که داده ها را با چه معماری ذخیره کنیم. در واقع به یک سیستم ذخیره سازی نیاز داریم که بتواند در صورت لزوم، بتوان به راحتی با تغییر مقیاس داده ها، این سیستم ذخیره ساز داده را نیز تغییر مقیاس داد.

امنیت – از آنجایی که اندازه ی داده ها عموما بزرگ است، قاعدتاً حفظ امنیت آن هم چالش دیگری محسوب می شود. احراز هویت کاربران، محدود کردن دسترسی بر اساس کاربر، ثبت تاریخچه ی دسترسی به داده ها، استفاده ی صحیح از رمزگذاری داده ها و ... ازجمله مواردی هستند که در حیطه ی امنیت جای می گیرند.

**نبود استعداد کافی** – پروژههای کلان داده ی بسیاری در سازمانهای بزرگ وجود دارد، اما وجود یک تیم باتجربه از توسعه دهندگان، متخصصان علم داده و همچنین تحلیل گرانی که دانش کافی در زمینه ی داده داشته باشند، هنوز هم به صورت یک چالش باقی مانده است.

۱-۶ صنایعی که از کلان داده ها استفاده می کنند

بنگاههای اقتصادی و صنایعی که بهطور گسترده، از دادههای عظیم (بیگ دیتا) استفاده میکنند عبارتاند از:

- ♦ صنعت بانکداری، بورس و اوراق بهادار
  - ♦ صنعت بيمه
  - ♦ تجارت خردهفروشی و عمدهفروشی
    - ♦ بنگاههای خدماتی

- ♦ ارائهدهندگان خدمات بهداشتی، درمانی و سلامت
- ♦ صنایع مخابرات، ارتباطات و اپراتورهای مخابراتی
  - ♦ صنعت رسانهها و سرگرمی
    - ♦ بنگاههای آموزشی
    - ♦ صنایع تولیدی و پخش
    - ♦ دولت و خدمات دولتی
      - ♦ صنعت حملونقل
  - ♦ صنایع انرژی، آب، برق و گاز

معمولاً بنگاههای اقتصادی و سازمانهای دولتی و خصوصی از کلان داده ها برای اهداف زیر استفاده می-کنند:

- ♦ متمایز شدن از رقبا
- ♦ به دست آوردن سهم بازار بیشتر
  - ♦ افزایش درآمد
  - ♦ درک بهتر مشتریان
- ♦ سودآوری از طریق سرویسهای جدید نوآورانه

بهره گیری از مزایای Big Data، معمولاً به سازمانها، میتواند برای تحقق سه هدف حیاتی زیر مورد استفاده قرار گیرد:

- ♦ تحویل سرویسهای هوشمندتری که منابع درآمدی جدیدی را تولید میکنند
  - ♦ تحول در عملیات برای دستیابی به برتری تجاری و سرویسدهی
- ♦ ساخت زیرساختهای هوشمندتر برای هدایت و تقویت سازگاری و کیفیت تجربه مشتری

## فصل ۲

# پایگاه دادههای NoSQL

پایگاه دادههای رابطهای و یا RDBMS از دههی ۱۹۷۰ مورد استفاده قرار گرفت و مطمئناً می توان از آن به عنوان یکی از فناوریهای تکامل یافته برای ذخیرهی دادهها و روابطشان یاد کرد. بااین حال، مشکلات ذخیره سازی در سیستمهای مبتنی بر وب، محدودیتهای پایگاههای داده رابطهایی را به چالش کشید. در نتیجه محققین و شرکتها را وادار ساخت تا روی قالبهای غیر سنتی ذخیرهی دادهها تحقیق و بررسی کنند. امروزه دادههای کاربران می توانند تا مقیاس چند ترابایت در یک روز افزایش یابند و باید در کمترین زمان ممکن برای میلیونها کاربر در سراسر دنیا قابل دسترس باشند.

تجزیه، تحلیل و بهخصوص ذخیرهسازی این حجم از اطلاعات در نوع خود یک چالش محسوب می شود. در چهارچوب یک سیستم تک گره، افزایش ظرفیت ذخیرهسازی گرهی محاسباتی، به معنای افزایش حافظهی اصلی و یا فضای دیسک بیشتر، با محدودیتهای اساسی سخت افزار مواجه می شود. زمانی که یک گره با محدویت ذخیرهسازی مواجه می شود، هیچ جایگزینی برای آن وجود ندارد، اما در یک سیستم توزیع شده می توان داده ها را در بین گرههای مختلف توزیع کرد. سابقاً، سیستمهای RDBMS به گونه ای طراحی نشده بودند که بتوانند به راحتی توزیع شوند و درنتیجه افزودن گرههای جدید برای متعادل کردن بار داده ها، امری بسیار پیچیده است. علاوه بر این، اغلب اوقات کارایی پایگاه داده ها به طور چشمگیری کاهش می یابد، چراکه عملیاتهای پیوند و تراکنش در محیطهای توزیع شده، بسیار پرهزینه هستند. البته، این مسئله به این معنا نیست که پایگاههای داده ای RDBMS منسوخ شده اند، بلکه برای نوع نیازهای خاص دیگری طراحی شده اند و در صورتی که پایگاههای داده ای گرینه باشند.

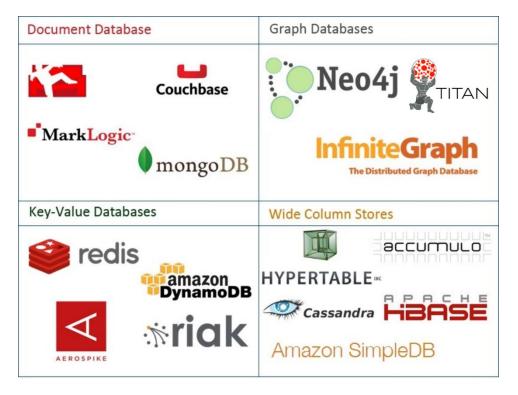
اگر بخواهیم دقیق تر به پایگاههای دادهای NoSQL بپردازیم، باید گفت که به عنوان روش ذخیرهسازی جایگزین و البته نه بر اساس مدلهای رابطهای، ارائه شده اند تا بتواند مشکلاتی را که پیش تر به آن اشاره شد، برطرف سازند. اصطلاح "NoSQL" توسط کارلو استروزی در سال ۱۹۸۸ مطرح شد و از آن برای اشاره به پایگاه دادهای متن بازی به نام NoSQL استفاده می شد که فاقد رابط SQL است. بار دیگر این اصطلاح در سال ۲۰۰۹، توسط اریک اونز در چهارچوب پدیدهای پیرامون پایگاههای داده توزیع شده ظاهر گشت. همچنین از طرفی دیگر برخی از متخصصان علوم داده به این مسئله اشاره کردهاند که الگوهای مدیریت اطلاعات در حوزههای جدیدی مانند اینترنت اشیاء و یا شبکههای اجتماعی در زمینه ی ذخیرهسازی دادهها، به تغییراتی بنیادی نیاز دارند. به همین دلیل، پایگاههای داده سنتی از عهده ی حجم کلان اطلاعاتی که در زمینههایی همچون اطلاعات RFIDs، GPS، آدرسهای IP دادهها و فرادادههای دستگاههای علمی و دادههای حس گر تولید می شوند، برنمی آیند و اصولا مدلهای ذخیرهسازی آنها برای این موارد کاربرد، یک روش بهینهای نیست.

در حالت کلی، پایگاهدادههای NoSQL غیر ساخت یافته هستند، یعنی دارای شِمای ثابت نیستند و رابط استفاده از آنها ساده است و به توسعه دهندگان این اجازه را می دهد تا بتوانند به سرعت شروع به استفاده از آن نمایند. علاوه بر این، به طور کلی این نوع پایگاههای داده مانع از عملیات پیوند در سطح ذخیرهسازی دادهها می شوند، چراکه چنین عملیاتی اغلب پرهزینه هستند و این وظیفه را به لایههای دیگر واگذار می کنند. در واقع این توسعه دهنده است که باید تصمیم بگیرد که آیا عملیات پیوند در سطح برنامه انجام شود و یا به عنوان جاگزینی برای آن به غیرنرمال سازی دادهها بپردازد. در حالت اول، احتمالاً اتخاذ این تصمیم منجر به جمع آوری دادهها از گرههای فیزیکی مختلف، بر اساس برخی از معیارها می شود و سپس بروی دادههای جمع آوری شده عملیات پیوند انجام می شود. این رویکرد نیازمند به توسعه ی بیشتر در سطح برنامه است، در سالهای اخیر چهارچوبهای متعددی، از جمله مدل برنامهنویسی نگاشت/کاهش، اسپارک و یا ابزار Pregel به طور خارق العادهای این وظیفه را به لطف فراهم نمودن مدلی برنامهنویسی برای پردازشهای توزیع شده و موازی، آسان کردهاند. برای مثال مدل نگاشت/کاهش دارای دو فاز نگاشت و کاهش است که فاز نگاشت بروی دادهها که در بین نودهای فیزیکی پخش شدهاند، اجرا شده و یکسری دادههای میانی تولید می کند که در فاز کاهش عملیات تجمیع سازی و ایجاد نتایج از این دادههای میانی انجام می پذیرد.

بسیاری از پایگاههای داده NoSQL برای حالت توزیع شده طراحی شدهاند که به نوبه ی خود اجازه می دهند تا ظرفیتشان را، آنهم تنها با افزودن گرههایی به زیرساخت افزایش دهند؛ این قابلیت با نام "مقیاس پذیری افقی" هم شناخته می شود. در پایگاههای دادهای دادهای افزودن گرههایی به زیرساخت افزایش دهند؛ این قابلیت با نام "مقیاس پذیری افقی استفاده می شود، که شامل تقسیم کردن و تبدیل رکورد دادهها به بخشهای مستقل و متعدد یا همان shard با استفاده از معیاری خاص نظیر شماره شناسه رکورد می شود. مکانیزم به کار گرفته شده دیگر مکانیسم تکرار است. یعنی رکورد دادهها در میان سرورهای متعدد تکرار می شود. این امر اجازه ی افزایش توان عملیاتی و رسیدن به قابلیت دسترس پذیری بالا را می دهد. هر دو مکانیسم بخش بندی و تکرار، دو مفهومی هستند که می توانند با ترکیب یکدیگر راه حلی برای مقیاس پذیری افقی در پایگاه دادههای غیر رابطه ایی بکار گرفته شوند.

در اکثر پیادهسازیها، الزامات و نیازمندیهای سختافزاری هر گره مطابق با مشخصات سرورهای ارزان قیمت و معمولی است تا بتوان هزینههای ساخت چنین سیستمهایی را کاهش داد و همچنین جایگزینی گرههای معیوب راحت باشد. ۲-۲ مدلهای دادهای در پایگاه دادههای غیر رابطهای

پایگاه دادههای NoSQL به دستهبندیهای مختلفی تقسیم میشوند، که هر کدام نوع خاصی از مدل داده را برای ذخیرهسازی داده توصیف می کنند. این دستهبندیها عبارتند از:



شکل ۱-۲

- ◄ کلید/مقدار: این نوع از پایگاه دادها اجازهی ذخیره کردن دادههای دلخواه را تحت نظارت یک کلید میدهند.
   روش کار آنها مشابه یک جدول هَش معمولی است، با این تفاوت که از کلیدهای توزیعی (و مقدارها) در میان مجموعهای از گرههای فیزیکی بهره میبرد. از جمله متدوالترین محصولات در این بخش میتوان به Redis اشاره کرد.
   BerkeleyDB و DynamoDB ،Riak
- سطر گسترده یا مبتنی بر ستون: در این مدل بجای ذخیره کردن سطری دادهها (یعنی همان شیوهای که در پایگاههای داده یا مبتنی بر ستون: در این مدل بجای ذخیره کردن سطری داده ستونی ذخیره می شوند. بنابراین، پایگاههای داده این بایگاههای داده ستونی ذخیره می شوند. بنابراین، بعضی از سطرها ممکن است شامل بخشی از ستونها نباشند. این پایگاه دادهها امکان انعطاف پذیری در تعریف داده را میدهند و اجازه ی اعمال الگوریتمهای فشرده سازی داده را در هر ستون میدهند. گذشته از این، ستونهایی داده را می دهند. گذشته از این، ستونهای که اغلب با یکدیگر جستجو نمی شوند، می توانند در گرههای مختلف توزیع شوند. Big Table و Big Table

- سندگرا: سند مجموعهای از فیلدها به همراه مقادیر است. برای مثال: نام= "رضا"، نام خانوادگی= "بخشایشی" یک سند دو فیلدی میباشد. اکثر این نوع از پایگاههای داده، سندها را در قالب دادههای نیمه ساخت یافته همچون سند دو فیلدی میباشد. اکثر این نوع از پایگاههای داده کلید/مقدار است، با این تفاوت که در این مورد کلید همواره شناسه سند میباشد و مقدار هم سندی از پیش تعریف شده از انواع شناخته (مثل که در این مورد کلید همواره شناسه که اجازه ی جستجو در فیلدها مختلف سند را میدهد. در این مدل پایگاه داده میتوان به CouchDB ، MongoDB اشاره کرد.
- گرافی: این نوع پایگاههای داده به قصد ذخیره کردن دادهها در ساختاری گراف مانند پدید آمدهاند. دادهها از طریق رأسها و کمانها و ویژگیهای مخصوص خودشان ارائه میشوند. اغلب پایگاههای داده گرافی حتی زمانی که رأسها در گرههای فیزیکی جداگانهای واقع شده باشند قادر به پیمایش گرافی کارآمدی هستند. علاوه بر این، اخیراً این نوع از پایگاه دادهای به خاطر کاربرد دادههای اجتماعی، بسیار مورد توجه قرار گرفته است. این میزان از توجه پیدهسازیهای جدیدی را به ارمغان آورده تا با نیازهای امروزی مطابقت داشته باشد. از Titan ،Neo۴j ویادههای گرافی یاد کرد.

#### ۳-۳ معیارهای گزینش یایگاه داده ۲-۳

برخی از معیارهایی که ممکن است در گزینش پایگاه دادهای NoSQL به عنوان سیستمهای ذخیرهسازی دادهها مفید واقع شوند، آورده شده است:

- ◄ تجزیه و تحلیل دادهها: برخی موقعیتها ایجاب می کند که دانش و اطلاعاتی از دادههای ذخیره شده در پایگاه داده استخراج کنیم. در میان روشهای موجود برای اجرای وظایف در محیط کلان داده، مدلهایی نظیر نگاشت/کاهش و یا ابزار اسپارک در میان سایرین برجسته تر هستند. در بسیاری از این چهارچوبهای پردازشی، توسعه دهنده باید کد جستجو را به زبان برنامهنویسی معینی ارائه کنند. اگرچه این روش نسبت به اعمال دستورات جستجوی GROUP BY، SELECT ... بسیار پیچیده تر است، ولی با همهی این اوصاف برای محیط کلان داده که حجم و سرعت پردازش دادهها بسیار اهمیت دارد، مناسبتر هستند. زبانهایی همچون Pig و الباده کوسته برنامهها را با نگاشت/کاهش و یا چهارچوب SQL در اسپارک توسعه برنامهها مبتنی بر درخواستهای رابطهای را آسان تر می کنند.
- مقیاس پذیری: پایگاه دادههای NoSQL به منظور ذخیرهسازی حجم عظیمی از دادهها و یا پشتیبانی از پردازش
   مورد نیاز، به واسطهی افزودن گرههای جدید به سیستم، طراحی شدهاند. علاوه بر این، عموماً این سیستمها بر

اساس این فلسفه طراحی شدهاند که شکست و خطا در گرهها امری عادی است و همیشه نسخههای تکثیر شده ی دادهها باید آماده ی دریافت درخواستها باشند. این نوع از طراحی در صورت خرابی در یکی از گرههای خوشه، از استحکام خوبی برخوردار است. در برخی از موارد، زمانی که خرابی گرهها دائمی به نظر میرسند، دادهها مجدداً به طور خود کار در میان گرههای در دسترس در کلاستر توزیع می گردند.

- ♦ انعطاف پذیر در شِمای دادهها: پایگاههای داده NoSQL از شِمای ثابتی برخوردار نیستند. پایگاه دادههای کلید/مقدار هیچگونه پیش فرضی دربارهی مقدارهای کلید ارائه نمیدهند. پایگاه دادههای سندگرا و سطر گسترده پذیرای تعداد زیادی از ستون-مقدارها هستند. در پایگاه دادهای گرافی، رأسها و کمانها می توانند هر نوع ساختاری داشته باشند. در مقابل، پایگاههای دادهای رابطهای از مجموعه جداولی با شِما ثابت تشکیل شده است تعداد فیلدهای آن در هر سطر ثابت است.
- ♦ استقرار سریع: به طور کلی، سیستمهای NoSQL میتوانند به آسانی در یک خوشه مستقر شوند. پیکربندی
   تکرارها و بخش بندی اصولاً به طور خود کار انجام می گیرند و انتخاب آنها را سرعت می بخشد.
- ♦ آگاهی از مکان دادهها: در مجموع از آنجایی که پایگاههای دادهای NoSQL مبتنی بر مدلهای توزیع شده طراحی شدهاند، دانستن قرارگیری مکان دادهها در خوشه و ارسال درخواست به گرهایی که داده در آن قرار دارد استفاده از پهنای باند شبکه را بطور چشمگیری بهبود میدهد. معمولاً این کار با استفاده از روشهایی نظیر مشخص کردن اینکه هر گره باید پذیرای چه محدودهای از کلیدها باشد، صورت میپذیرد.

علاوه بر این، انتخاب پایگاه داده NoSQL باید بر اساس نوع دادهای که قرار است ذخیره شود و همچنین روش دسترسی به آن (خواندن و نوشتن) باشد. مثالی بدیهی برای آن، وبسایتهایی است که در هر ثانیه میلیونها بازدید کننده دارند و دادههایشان برای پشتیبانی از عملکردی جدید می تواند کاملاً تغییر یابند. فیسبوک، گوگل و آمازون برخی از نمونههای بارز این مثالها هستند. در این سیستمها دادهها می تواند بدون هیچگونه محدودیتی رشد یابند، در نتیجه زیرساخت سیستم باید اجازهی افزایش فضای ذخیره سازی را، بدون آن که هیچ خللی در عملکرد آن وارد شود، بدهد. در این مواقع، به ندرت از پایگاههای دادهی رابطهای از عهدهی مدیریت این نیازها برمی آید.

باید توجه داشته باشید که پایگاههای دادهای ترکیبی نیز وجود دارند که قادر به ذخیره کردن بیش از یک شمای داده هستند. برای نمونه می توان از OrientDB، OpenLink Virtuoso و AlchemyDB به عنوان پایگاههای دادهای چند-شمایی نام برد.

اخیراً سیستم پایگاه داده جدیدی به نام "پایگاههای داده NewSQL" به عنوان راهحلی در کنار پایگاههای داده ایم البطهای هستند و پایگاههای داده سنتی RDBMS معرفی شده است. پایگاههای دادهای البطهای پایگاههای داده ای رابطهای هستند که بخشبندی، تکرار خودکار و پردازش تراکنشهای توزیع شده را پشتیبانی میکنند و خاصیت ACID را حتی در سراسر بخشها تضمین میکنند. برای ذکر نمونه از این نوع پایگاه داده میتوان به VoltDB ،NuoDB و Clustrix اشاره کرد. برای مثال Google Spanner سیستم پایگاه داده ی توزیعی است که توسط شرکت گوگل خلق شده است و تراکنشهای توزیع شده را پشتیبانی میکند و به عنوان جایگزینی برای Megastore که سیستم ذخیرهسازی بر اساس NewSQL قبل است، طراحی شده است. با این همه، همانند پایگاههای داده NoSQL، ضروری است که پایگاههای داده NewSQL قبل از آن که توسط سازمانی به کار گرفته شود، مورد تجزیه و تحلیل عمیق بگیرد.

## فصل ۳

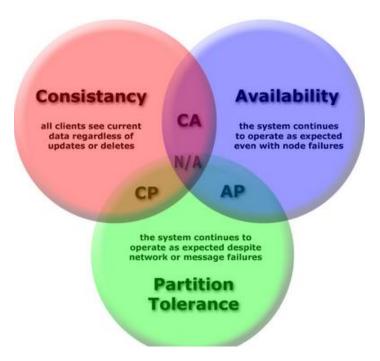
سازگاری دادهها در پایگاهدادههای غیررابطهای سازگاری و دسترسپذیر بودن دادهها در سیستمهای توزیعشده از جمله مهمترین چالشهای طراحی یک چنین سیستمهایی میباشد. پایگاهدادههای غیررابطهایی نیز نوعی از سیستمهای توزیعشده محسوب میشوند و ایجاد سازگاری دادهها در بین گرههای یک خوشه پایگاهداده، باعث شده است تا طراحی و نحوه تعامل با این پایگاهدادهها نسبت به پایگاهدادههای رابطهای متفاوت باشد.

#### ۳-۱ تئورى CAP

در طراحی سیستمهای توزیع شده تئوری وجود دارد که بیان میکند در یک سیستم توزیعشده باید از بین سه ویژگی سازگاری داده، در دسترس بودن و تحمل در برار تقسیم خوشه دو مورد را انتخاب کرد. این محدودیت ذاتی سیستمهای توزیع شده، که با نام تئوری (CAP یا تئوری بروور شناخته میشود، بیان میکند که غیرممکن است ویژگیهای زیر را در یک سیستم توزیع شده به صورت همزمان داشته باشیم. از آنجایی که پایگاه دادههای غیررابطهای نیز نوعی سیستم توزیعشده بحساب میآیند، در نتیجه این تئوری در مورد پایگاه دادههای غیررابطهایی نیز صدق میکند. به منظور درک بهتر این تئوری هریک از این ویژگیها را تعریف میکنیم:

- • سازگاری: اگر این ویژگی برقرار شود، تضمین میشود که در زمان خواندن دادهها از پایگاه داده بروزترین داده در اختیار کاربر قرار بگیرد و یا سیستم خطایی مبنی بر نقض سازگاری ارسال می کند.
- ◄ در دسترس بودن: برقرار بودن این ویژگی بیان می کند که سیستم در درصورت وجود پاسخ حتما آن را به عنوان
   پاسخ پرسوجو ارسال می کند. اگرچه ممکن است این پاسخ بروزترین داده در پایگاه داده نباشد.
- ◄ تحمل در برابر تقسیم خوشه: اگر سیستم دارای این ویژگی باشد، حتی با وجود شکست در برخی از قسمتهای
   شبکه (و تقسیم شدن خوشه به چندین قسمت مجزا) بتواند به کار خود ادامه دهد.

در سال ۲۰۰۰ میلادی، اریک بروور این فرضیهٔ را مطرح کرد، که در هر زمان تنها دو مورد از سه مشخصهٔ گفته شده قابل تضمین در یک سیستم توزیعشده است. چند سال بعد، گیلبرت و لینچ این فرضیه را به صورت رسمی و مدون بیان کردند، و نتیجه گرفتند که در هر سیستم توزیع شده تنها دستیابی به یکی از ترکیبهای زیر ممکن است: AP (در دسترس بودن و سازگاری). و تحمل در برابر تقسیم خوشه) یا AC (در دسترس بودن و سازگاری). جدول زیر، برخی از پایگاه دادههای غیررابطهایی را براساس هریک از این سه دسته نشان می دهد.



شکل ۱-۳

در هر گروه، پایگاهدادهها براساس ویژگیهای تئوری CAP ، مجدداً طبقهبندی میشوند. همانطور که نشان داده شده است، بیشتر پایگاهدادههای بررسی شده در گروههای «AP» و «CP» دستهبندی میشوند. زیرا فراهم نکردن P (تحمل در برابر تقسیم خوشه) در سیستمهای توزیع شده تنها با این فرض ممکن است، که شبکهٔ زیرساخت هیچگاه دچار خرابی نشده و اتصال قطع نخواهد شد، که در عمل در سیستمهای توزیع شده این امر با تقریب بسیار بالایی غیرممکن است. برخی از پایگاهدادهها، نظیر P (P مشاهده میشوند. و یا eventual consistency را با فراهم کردن دسترسیپذیری بالا تضمین کنند؛ به همین منظور در هر دو ستون P و P مشاهده میشوند.

AC	СР	АР	الگوی داده
Infinispan	Infinispan, Membase/CouchBase, BerkeleyDB	Riak, Infinispan, Redis, Voldemort, Hazelcast	کلید/مقدار
-	HBase, Hypertable	Cassandra	سطر گسترده
-	MongoDB	MongoDB, RavenDB, CouchDB, Terrastore	سندگرا
-	InfiniteGraph	Neof-J, HypergraphDB, BigData, AllegroGraph, InfoGrid, InfiniteGraph	گرافی

شکل ۲-۳

البته پس از چندین سال تئوری جدیدتری نسبت به تئوری CAP با عنوان تئوری PACELC مطرح شد که این تئوری عنوان می کند اگر سیستم دچار هیچگونه نقصی نشد (خوشه بصورت نرمال بکار خود ادامه دهد و هیچگونه شکستی آن را به دو یا چند قسمت تقسیم نکند) نیز باید بین تاخیر پاسخ و سازگاری دادهها یکی را انتخاب کنیم و در واقع موازنهای بین این دو فاکتور برقرار کنیم.

#### ۳-۲ ویژگی های ACID و BASE

در سال ۱۹۷۰ میلادی، جیم گری مفهوم تراکنش را که به معنی واحد کاری در یک سیستم پایگاه داده است، ارائه کرد. یک تراکنش باید چهار ویژگی اصلی را دارا باشد: تجزیهناپذیری، سازگاری، ایزوله بودن و پایایی. این ویژگیها، که با سرواژه ACID شناخته میشوند، طراحی سیستمهای پایگاه داده را پیچیده میکنند؛ و این پیچیدگی در سیستمهای پایگاه داده توزیع شده، که داده در بخشهای مختلفی داخل یک شبکهٔ کامپیوتری پخش میشوند، بیشتر خواهد بود. با این حال، این خصیصه، با تضمین اینکه هر عملیات، سازگاری در پایگاه داده را حفظ میکند، کار توسعهدهندگان را ساده میکند. همچنین به دلیل آنکه عملیاتها ذاتاً مستعد شکست و ایجاد تأخیر در شبکه هستند و به منظور تضمین موفقیت تراکنش، پیشربینیهای فوقالعادهای باید در نظر گرفته شود.

در سالهای اخیر، سیستمهای مدیریت پایگاهدادههای رابطهای توزیع شده، به منظور حفظ سازگاری دادهها در طول پارتیشنها، امکان اجرای تراکنشها به وسیلهٔ پروتکلهای خاص را فراهم کردهاند. نمونهای از این RDBMSها، مگااستور است، پایگاهدادهای توزیع شده که قابلیت پشتیبانی از تراکنشهای ACID در جداولی خاص و پشتیبانی محدود تراکنشها در جداول داده مختلف را داراست.

مگااستور توسط BigTable پشتیبانی می شود؛ اما برخلاف BigTable، برای پشتیبانی از روابط سلسلهای در بین جداول، از یک زبان اسکیما استفاده می کند و مدلی نیمه رابطهای را فراهم می کند. با این که مگااستور (در مقایسه با استفادهٔ مستقیم از یک زبان اسکیما استفاده می کند و مدلی نیمه رابطهای را فراهم می کند. و نوشتها از BigTable کارآیی خوبی نداشت، در بسیاری از کاربردها، نیاز به سادگی اسکیما و تضمین همگامسازی رونوشتها در مگااستور توسط نسخهای از الگوریتم Paxos همگام می شوند. احساس می شد. مانند بسیاری از پایگاههای داده، رونوشتها در مگااستور توسط نسخهای از الگوریتم Poxos همگام می شوند. یکی از پروتکلهای رایج برای اجرای تراکنشها در محیطهای توزیع شده در این سیستمها، PC۲ (پروتکل تثبیت دو مرحلهای) است. این پروتکل حتی در سرویسهای وب نیز رواج یافته، و استفاده از تراکنشها را حتی در معماریهای مبتنی بر REST نیز ممکن ساخته است. پروتکل PC۲، از دو بخش اصلی تشکیل شده است:

مرحلهای که مولفه هماهنگکننده، از پایگاهدادههایی که درگیر تراکنش هست درخواست عملیات پیش تثبیت را میکند. از اگر تمام پایگاهدادهها تمام عملیاتها را به اتمام برسانند، مرحلهٔ ۲ صورت میگیرد. در غیر این صورت، حتی اگر یکی از پایگاهدادهها تغییرات صورت گرفته را بازگردانی میکنند.

هماهنگ کننده از پایگاهدادهها درخواست اجرا عملیات تثبیت را می کند. اگر هر کدام از پایگاهدادهها عملیات تثبیت را رد کنند، بازگردانی در تمام پایگاهدادهها اجرا می شود.

براساس تئوری CAP، استفاده از پروتکلی مانند PC۲ (برای مثال در سیستم CP) اثرات منفی روی دسترسپذیری سیستم خواهد داشت. به این معنی که اگر پایگاهدادهای شکست بخورد (برای مثال، به دلیل عملکرد نادرست سختافزاری)، تمام تراکنشهای اجرا شده در بازه خرابی شکست خواهد خورد. به منظور اندازهگیری شدت این تأثیر، در دسترس بودن هر عملکرد می تواند به عنوان حاصل در دسترس بودن اجزای منفرد در گیر در این عملیات محاسبه شوند. برای مثال، اگر هر پارتیشن پایگاهداده ۹۹٫۹٪ در دسترس باشد، یعنی ۴۳ دقیقه در هر ماه میتواند در دسترس نباشد، اجرا تثبیت با استفاده از پروتکل PC۲ بر ۲ پارتیشن در دسترس بودن را به ۹۹۰۸٪ کاهش میدهد، یعنی ۸۶ دقیقه در ماه خارج از دسترس بودن. علاوه بر این، PC۲ پروتکلی مسدود کننده است، به این معنی که پایگاهدادههای درگیر در یک تراکنش هنگام روند اجرا تثبیت به صورت موازی قابل استفاده نیستند. در نتیجه، با افزایش تعداد تراکنشهای همزمان، تأخیر سیستم بیشتر خواهد شد. به همین دلیل، در بسیاری از رویکردهای پایگاهدادههای NoSQL، تصمیم گرفته شد که محدودیتهای سازگاری کاهش داده شوند. این رویکردها با نام BASE شناخته میشوند. ایده پیادهسازی این مفهوم در سیستمها این است که، به جای شکست کل سیستم، اجازه دهد بخشی از سیستم دچار شکست شود؛ که منجر به دسترسی بیشتر سیستم خواهد شد. طراحی سیستمهای BASE، و پایگاه داده های NoSQL مبتنی بر BASE به صورت خاص، اجرای عملکر دهای مشخصی را که رونوشتها (کپیهایی از دادهها) را در حالت ناسازگار قرار میدهند، مجاز میدانند. همانطور که از نام آن بر میآید، سیستمهای BASE، با معرفی به اصطلاح حالت نرم رونوشت، دسترسی پذیری سیستم را در اولویت قرار میدهند، یعنی هر پارتیشن ممکن است دچار شکست شود و به کمک رونوشتها بازسازی شود. از طرفی، این سیستمها مکانیزمی نیز برای همگامسازی رونوشتها تعبیه کردهاند. این مکانیزم با عنوان Eventual Consistency شناخته می شود، تکنیکی که بر اساس برخی معیارهایی سیستم را به حالت سازگار برمی گرداند و ناسازگاریها را حل می کند. اگرچه Eventual Consistency تضمین نمی کند که کاربر در هنگام خواندن دقیقاً مقدار مشابهای از تمام رونوشتها را دریافت کند، اما با

توجه به نوع کاربرد از پایگاهدادهها، وجود این درخواستهای خواندن در بسیاری از کاربردها قابل قبول است. برای مثال پایگاهداده Cassandra در پایگاهدادههای NoSQL، سیاستهای زیر را درجهت بروزرسانی رونوشتها پیادهسازی می کند:

- ♦ اصلاح در هنگام خواندن: ناسازگاریها در طول خواندن داده اصلاح می شوند. به این معنی که نوشتن داده ممکن است ناسازگاریهایی برجای بگذارد، که تنها بعد از عملیات خواندن برطرف خواهد شد. در این روند، مولفه دریافت کننده، داده را از مجموعهای از رو نوشتها می خواند و اگر مقادیر ناسازگار بیابد، موظف است که رونوشتهایی که دادههای قدیمی دارند را بروز رسانی کند. قابل توجه است که تضاد در رونوشتها فقط زمانی رفع خواهد شد که دادهها در گیر عملیات خواندن باشند.
- ◄ اصلاح در زمان نوشتن: زمانی که دادهها(رونوشتها) بر روی مجموعهای از گرهها نوشته می شود، ممکن است تعدادی از گرهها در دسترس مولفه هماهنگ کننده نباشند. با استفاده از این سیاست، به روزرسانی ها برای زمانی که گرهها در دسترس باشند زمان بندی می شوند تا اجرا شوند.
- ◄ اصلاح ناهمگام: تصحیح کردن نه بخشی از عملیات نوشتن و نه عملیات خواندن است، همگامسازی می تواند با
   گذشت زمان از آخرین به روزرسانی، مقدار عملیاتهای نوشتن یا رخدادهای دیگری که نشان می دهد پایگاه داده
   در حالت سازگار نیست، آغاز شود.

علاوه بر سازگاری در عملیاتهای خواندن و نوشتن، در سیستمهای ذخیرهسازی توزیع شده مفهوم پایایی به وجود می آید، که توانایی یک سیستم در ماندگاری دادهها حتی با وجود شکستها است. به همین دلیل پیش از نمایش پیغام موفقیت عملیات به کاربر، دادهها بر روی تعدادی حافظهٔ غیرفرار نوشته می شود. در سیستمهای Eventually Consistent ، مکانیزمهایی برای درجه بندی پایایی و سازگاری سیستم وجود دارد. در ادامه، این مفاهیم را با کمک یک مثال روشن می کنیم. فرض کنید N تعداد گرههایی است که کلیدی بر روی آنها رونوشت شده است، M تعداد گرههایی که برای موفق خواندن عمل نوشتن مورد نیاز باشد، و N تعداد گرههایی باشد که عملیات خواندن روی آنها اجرا می شود. جدول پایین پیکربندی های مختلف برای N و N و همچنین نتایج اعمال این پیکربندی ها را نشان می دهد. هر مقدار به تعداد رونوشتهایی که برای تأیید موفقیت عملیات لازم است اشاره دارد.

سازگاری قوی با اجرای W+R>N اتفاق می افتد؛ یعنی مجموعهٔ گرههای در گیر در عملیاتهای خواندن و نوشتن طوری هم پوشانی دارند که همیشه عملیاتهای خواندن آخرین نسخه از داده را به دست می آورند. معمولاً RDBMsها شرط W=N را دارند؛ تمام رونوشتها ماندگار هستند و همچنین دارای شرط W=N

بروز را بازمی گرداند. سازگاری ضعیف زمانی به وجود می آید که  $W+R \le N$  برقرار می شود. در این شرایط عملیاتهای خواندن ممکن است دادههای قدیمی دریافت کنند. Eventual Consistency، مورد خاصی از سازگاری ضعیف است که در آن تضمین می شود، اگر دادهای بر روی سیستم نوشته می شود، نهایتاً به تمام رونوشتها فرستاده خواهد شد. این موضوع بستگی به تأخیر شبکه، تعداد رونوشتها و بار سیستم و معیارهای دیگری دارد.

اگر نیاز باشد عملیاتهای نوشتن سریع تر صورت بگیرد، می توان با قبول پایایی کمتر، روی یک یا مجموعهای کمتر از گرهها انجام شوند. اگر W=V باشد، کاربر نوشتن سریع، اما با کمترین پایایی ممکن را تجربه می کند، زیرا هیچ تأییدیهای مبنی بر موفقیت آمیز بودن موفقیت آمیز بودن عملیات نوشتن وجود ندارد. اگر W=V، دادهها حداقل باید در یک گره نوشته شوند تا موفقیت آمیز بودن عملیات نوشتن به کاربر بازگردانده شود، و در نتیجه پایایی را به نسبت W=V بهبود می بخشد. به صورت مشابه می توان عملیات خواندن را بهینه ساخت. انتخاب W=V به عنوان یک گزینه مطرح نیست. برای دستیابی به مقدار بهینه برای خواندن می توان از W=V استفاده کرد. در بعضی مواقع (مثل استفاده از سیاست اصلاح در زمان خواندن)، ممکن است ملزم به خواندن از تمام گرهها باشیم، یعنی W=V و با وجود کاهش سرعت عملیات، نسخههای متفاوت داده را ادغام کنیم. طرحی میانه برای نوشتن یا خواندن، قاعده حدنصاب می باشد، به این صورت که عملیات (خواندن یا نوشتن) روی زیرمجموعهای از گرهها انجام می شود. معمولاً، مقدار استفاده شده در قاعده حدنصاب W=V است، به طوری که ۲ نوشتن یا خواندن متوالی حداقل در یک گره مشتر ک باشند.

خواندن (R)	نوشتن (W)	مقدار
بدون کاربرد	انتظار هیچ تأییدیهای از هیچ گرهای نداریم (امکان شکست وجود دارد)	o
خواندن از طریق یکی از رونوشتها انجام میگیرد (حالت بهینهٔ خواندن)	یک تأییدیهٔ واحد کافی است (حالت بهینه در نوشتن)	1
خواندن از طریق مجموعهای از رونوشتها انجام میگیرد (ممکن است نیاز به رفع اختلافات سمت کاربر باشد)	انتظار تأییدیهٔ از تعدادی از رونوشتها را داریم	M <n (حدنصاب)،="" m<="" th=""></n>
خواندن از طریق تمام رونوشتها صورت میگیرد که باعث افزایش تأخیر عملیات خواندن میشود	انتظار تأییدیه از تمام رونوشتها را داریم (دسترسی کاهش مییابد، اما پایایی افزایش پیدا میکند)	N (تمام گرهها)

شکل ۳-۳

در پایگاه دادههای غیررابطهای علاوه بر توجه به ملاحظات سازگاری و دسترسپذیری دادهها، نوع مدل دادهایی که یک پایگاه داده پشتیبانی می کند نیز بسیار اهمیت دارد و در تصمیم گیری انتخاب یک ابزار مناسب برای ذخیره دادهها نقش بسزایی دارد.

## فصل ۴

# ماشین مجازی

#### ۱-۴ معرفی

یک ماشین مجازی، در ابتدا توسط Popek and Goldberg به صورت "یک نسخه کپی شده از روی یک ماشین واقعی، به صورت کارا و ایزوله شده" تعریف شد. استفادههای کنونی، ماشینهای مجازیای را شامل می شود که هیچ ارتباط با سخت افزار واقعی ندارند.

ماشینهای مجازی، بر اساس استفاده و درجه ارتباط به ماشین واقعی، به دو دسته اصلی تقسیم میشوند.

یک ماشین مجازی سیستمی یک زیرساخت محاسباتی کامل را فراهم میکند که از اجرای یک سیستمعامل کامل پشتیبانی میکند.

در مقابل، یک ماشین مجازی فرایند، برای اجرای یک برنامه واحد طراحی شده، که این به این معناست که صرفاً از یک فرایند خاص پشتیبانی می کند.

یک ویژگی مهم یک ماشین مجازی، این است که نرمافزاری که درون آن در حال اجراست، با منابع و سطوح انتزاعی که توسط ماشین مجازی اعمال می شود، محدود شده است – یعنی نمی تواند از دنیای مجازی خود خارج شود.

نرم افزار vmware workstation ابزاری مفید است که این امکان را برای شما فراهم می آورد تا چندین سیستم عامل مختلف را روی ماشین خود نصب کنید و این توانایی را داشته باشید که بین سیستم عامل های مختلف بر حسب نیاز سوئیچ کرده و از مزایای OS های مختلف بهره مند شوید. یکی از مواردی که ما را ناگزیر به استفاده از این نرم افزار می کند نیاز به استفاده از سیستم عامل لینوکس است، خصوصا برای کسانی که کاربر ویندوز هستند.



شکل ۱-۴

۲-۲ آموزش نصب

آخرین نسخه نرم افزار vmware workstation را دریافت کرده و نصب می کنیم.

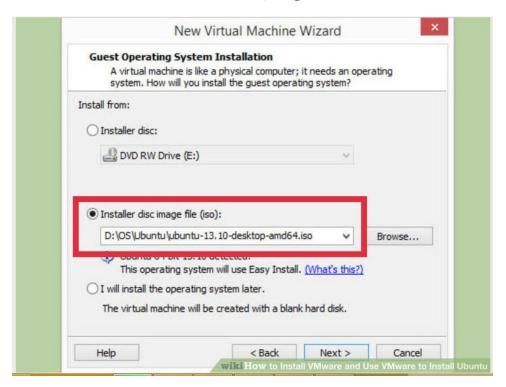
پس از نصب نرم افزار، نسخه مورد نظر از سیستم عامل ubuntu را دریافت کرده و اقدام به نصب آن بر روی ماشین مجازی می کنیم:

۱-گزینه Typical را انتخاب می کنیم.



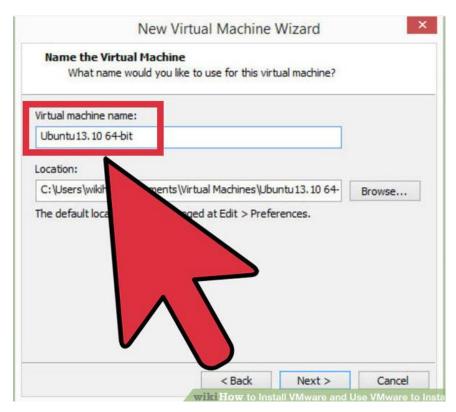
شکل ۲-٤

#### ۲- آدرس فایل ایزوی Ubuntu را به vmware می دهیم.



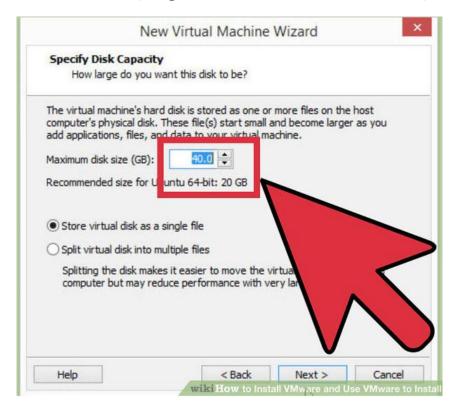
شکل ۳-۴

۳- نام ماشین مجازی و محل ذخیره سازی آن را بر روی سیستم خود انتخاب می کنیم.



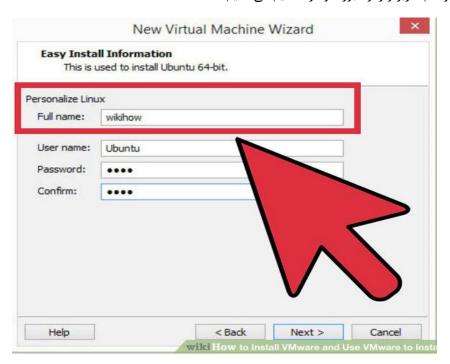
**۴-۴** شکل

#### ۴- میزان فضای لازم را بر حسب نیاز، از هارد خود به ماشین اختصاص می دهیم.



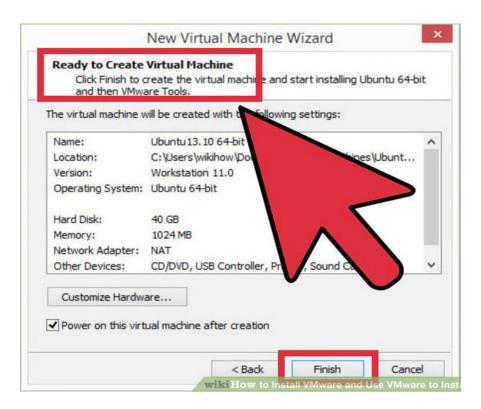
شکل ۵-۴

 $\Delta$  نام کامپیوتر، نام کاربر و رمز عبور خود را تنظیم می کنیم.



شکل ۶-۴

9- اگر نیاز به تنظیمات خاص سخت افزاری برای ماشین مجازی خود هستید می توانید از طریق Customized این کار را انجام دهید. در غیر اینصورت با فشردن دکمه Finish کار ساخت ماشین مجازی را به پایان ببرید.

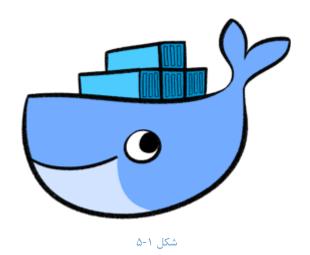


شکل ۲-۴

پس از طی کردن مراحل فوق، اقدام به اجرای ماشین مجازی می کنیم و در اولین اجرا سیستم عامل اوبونتو را نصب می کنیم.

# فصل ۵

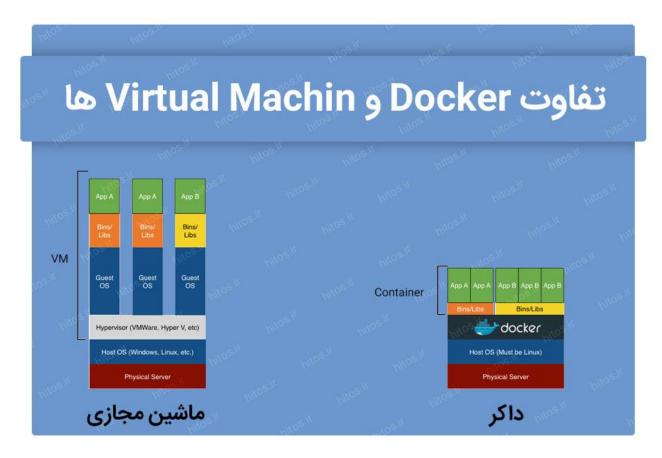
# DOCKER-اکر



#### ۱-۵ معرفی

Docker یک سکوی متن باز برای ساخت، طراحی و اجرای اپلیکیشنهای توزیع شده است. توسط داکر می توانید اپلیکیشن های خود را سریع تر و راحت تر منتشر کنید. Docker به صورتی عمل می کند که عملیات بسته بندی، حمل و توسعه هر برنامه کاربردی که به صورت سبک و قابل حمل ایجاد شده است را بطور خودکار انجام دهد. از دیگر ویژگیهای این پلتفرم، امکان گسترش سرویسهای قابل توسعه به شیوه ای امن و قابل اعتماد در طیف گسترده ای از پلتفرمها است. از دیگر قابلیت های داکر می توان به انتقال اپلیکیشنها و انعطاف پذیری زیر ساخت، به روز رسانی پویا و ایجاد تغییرات در لحظه را نام برد. داکر هیچ سیستم عامل جدیدی ایجاد نمی کند. بلکه این امکان را به بسته نرم افزاری ایجاد شده می دهد که از Rernel اصلی سیستم عاملی که بر روی آن نصب شده است استفاده نماید و در زمان انتقال نیز فقط Package نرم افزاری منتقل می شود املی سیستم عاملی که بر روی آن نصب شده است استفاده نماید و در زمان انتقال نیز فقط Hypervisor خدف شده و اینکار باعث می گردد که کارایی سیستم ما به شدت افزایش یابد. زیرا یک لایه واسط به نام Hypervisor حذف شده و اینکار باعث می گردد که کارایی سیستم ما به شدت افزایش یابد. زیرا یک کاملا ایزوله شده است.

یکی از مهمترین فاکتورهایی که Docker دارد Open Source بودن آن است. متن باز بودن بدین معنی میباشد که هر کسی میتواند Docker را تهیه و سورس آن را تغییر بدهد و یک محصول جدید معرفی کند و یا اینکه قابلیتهای جدیدی به آن اضافه کند که تا به حال بر روی آن وجود نداشته است. شما میتوانید Docker Container های مختلفی بر روی یک سیستم پیاده سازی کرده، بطوریکه تمامی آنها در یک فضای ایزوله شده قرار داشته و از سیستم میزبان هم مجزا باشند. با استفاده از این پلتفرم، میتوانید کل چرخهی توسعه، تست، توزیع و مدیریت را با استفاده از رابط کاربری مستحکم طراحی کنید.



شکل ۲-۵

#### ۳-۵ داکر برای چه کسانی مناسب است؟

داکر ابزاری است که هم برای برنامهنویسها و هم به برای مدیران شبکه مناسب است و به همین خاطر هم برخی اوقات به Docker ابزاری است که هم برای برنامهنویسها و Developer و Developer است. برای برنامهنویسها Docker نام یو این معنا است که فقط روی کدنویسی خودتان تمرکز کنید و دغدغه اینکه کد برنامه شما قرار است بر روی چه سیستمعاملی با چه نیازمندیهایی نصب شود را نداشته باشید. این کار را Docker برای شما انجام می دهد. از طرفی هزاران برنامه و نزم افزار متنوع وجود دارند که برای کار کردن در محیط Docker طراحی شده اند و شما به عنوان یک متخصص IT می توانید به راحتی از آنها در مجموعه خودتان در قالب یک Docker Container استفاده کنید. از طرفی در محیطهای عملیاتی Docker این امکان را به همه می دهد که چندین برنامه را همزمان بر روی یک سیستم فیزیکی نصب و اجرا کنند و اینها هیچکدام با یکدیگر کوچکترین ارتباطی نداشته باشند و بصورت کاملاً ایزوله در مجموعه فعالیت نمایند.

#### 4-4 مكانيزم كارى DOCKER چگونه است؟

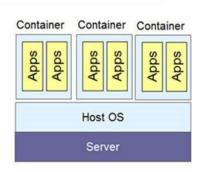
داکر یک لایه واسط بین سیستمعامل اصلی شما و بسته نرمافزاری تان ایجاد کرده و در واقع با استفاده از این لایه واسط نرمافزارها را از همدیگر ایزوله می کند، هیچکدام از نرمافزارها از وجود نرمافزار دیگر بر روی سیستم خبری ندارند. این مکانیزم یک چیز عجیب و غریب برای لینوکس نیست، در سیستمعامل لینوکس قابلیتهایی برای ایزولهسازی منابع وجود داشته و دارند که هم هسته سیستمعامل و هم گروهها و منابع سختافزاری و نرمافزاری سیستمعامل را بصورت ایزوله شده در اختیار نرمافزارها قرار می دهند که Docker نیز از آنها استفاده می کند. برای مثال قابلیتهای egroups و kernel namespace از جمله مواردی هستند که Docker از آنها برای کار خودش استفاده می کند. قابلیتی مثل Docker باعث میشود که این موارد شامل: process میشود که این موارد شامل: mount هیچ دیدی از محیطی که در آن اجرا میشوند نداشته باشند که این موارد شامل: egroups می کند. از طرفی قابلیتی مثل Docker محدودیتهای دسترسی به منابع: I/O ، RAM، CPU و شبکه را ایجاد می کند. این موارد شامی اشتراکی محدودیتهای دسترسی به منابع: از برای نرمافزارهای ما به ارمغان می آورد. اما به عنوان یک مکانیزم امنیتی شناخته (Shared Enviroment) امنیت را نیز برای نرمافزارهای ما به ارمغان می آورد. اما به عنوان یک مکانیزم امنیتی شناخته نمی شود. شما به عنوان یک برنامهنویس یا شبکه کار بایستی سیستمهامل Docker را بصورت جداگانه امن کنید.

#### ۵-۵ داکر هاب

یک سرویس اشتراک گذاری تهیه شده توسط شرکت Docker است که شامل مخزنی از imageهای آماده برای Docker است.

این مخزن حاوی دهها هزار برنامه و سیستم عامل است که می توان به آن imageهایی را هم اضافه کرد.

#### -8 کانتینر داکر



شکل ۳-۵

در واقع می توان گفت Container ظرفی است که Imageها را در آن اجرا می کنند. Containerها از روی Imageها در واقع می توان گفت Container ظرفی است که Lentosها را در آن اجرا می کنند. مثلا فرض کنید از یک Centos چند Container می سازیم و در هر کدام تغییرات متفاوتی اعمال می کنیم.

 $V-\Delta$  نصب داکر بر روی اوبونتو

برای انجام دستورات زیر نیاز دارید که دسترسی root داشته باشید. از آنجا که بسته (package) موجود در مخزن اوبونتو ۱۶٬۰۴ برای نصب داکر ممکن است آخرین نسخه نباشد، پیشنهاد می شود آخرین نسخه را از مخزن رسمی داکر دریافت کنید.

برای این کار ابتدا اطلاعات تمام بسته ها را بروز رسانی کنید:

sudo apt-get update

برای نصب داکر، کلید GPG مخصوص مخزن رسمی داکر را به سیستم خود اضافه کنید:

سیس مخزن داکر را به منابع APT اضافه کنید تا بتوانید با کمک دستور apt-get بسته های این مخزن را نصب کنید:

sudo apt-add-repository 'deb <a href="https://apt.dockerproject.org/repo">https://apt.dockerproject.org/repo</a> ubuntu-xenial main'

در قدم بعدی، دوباره اطلاعات بسته ها را که این بار شامل مخزن جدید داکر میشود بروز رسانی کنید:

sudo apt-get update

قبل از نصب مطمئن شوید که موتور داکر را از مخزن پروژه داکر دانلود می کنید، نه از مخزن پیش فرض اوبونتو. برای این کار دستور زیر را وارد کنید:

apt-cache policy docker-engine

و می بایست خروجی زیر را مشاهده کنید:

Packages \,\\\,\--~xenial \delta \cdots \delta \cdot \https://apt.dockerproject.org/repo ubuntu-xenial/main amd% Packages

این پیام نشان میدهد که گزینه انتخابی برای نصب، مخزن پروژه داکر است. البته نسخه نشان داده شده برای شما ممکن است متفاوت باشد ولی آدرس مخزن باید حتما در سایت apt.dockerproject.org باشد.

در نهایت، موتور داکر را نصب کنید:

sudo apt-get install -y docker-engine

زمانی که عملیات نصب به پایان رسید، موتور داکر به صورت خودکار اجرا شده و پردازه داکر برای اجرا در هنگام راه اندازی سیستم (boot) فعال شده است. با دستور زیر می توانید وضعیت اجرایی آن را چک کنید:

sudo systemctl status docker

نتایج باید مشابه زیر باشد که وضعیت سرویس را در حال اجرا و فعال نشان میدهد (Active & running):

docker.service - Docker Application Container Engine Loaded: loaded (/lib/systemd/system/docker.service; enabled; vendor preset: enabled) Active: active (running) since Sun ۲۰۱۷-۱۰-۰۱ ۰۶:۵۳:۵۲ CDT; ۱ weeks ۳ days ago Docs:

https://docs.docker.com Main PID: YF9 (docker)

در این مرحله نصب داکر تمام شده است.

اجرای دستورات داکر بدون نیاز به sudo

برای اجرای دستورات داکر می بایست آنها را با کمک دستور sudo اجرا کنید و در واقع نیاز به سطح دسترسی root دارید. اگر تمایل دارید بتوانید این دستورات را بدون sudo اجرا کنید میتوانید نام کاربری خود را به گروه داکر که در حین نصب ساخته شده است، اضافه کنید.

برای این منظور دستور زیر را پس از جایگزین کردن نام کاربری مورد نظرتان اجرا کنید:

sudo usermod -aG docker USERNAME

حال میتوانید دستورات داکر را بدون نیاز به sudo اجرا کنید، ولی دقت کنید که این کار در عمل به هر کاربری که عضو گروه docker شده باشد سطح دسترسی root میدهد.

 $\Delta - \Lambda$  استفاده از داکر برای پروژه

پس از نصب آن بر روی سیستم، یک image از اوبونتو را از داکر هاب دریافت می کنیم و بر روی آن، هدوپ و سایر موارد را نصب می کنیم. برای این منظور به صورت زیر عمل می کنیم.

۱- با توجه به فیلتر بودن سایت داکر هاب، از سایت های ایرانی موجود استفاده کرده و ایمیج مورد نظر را دریافت می کنیم:

#### http://elastico.io/

docker pull hub.elastico.io/library/image-name

نام image مورد نظر را در انتهای دستور فوق قرار داده (به جای image-name) تا دریافت صورت پذیرد.

شکل ۴-۵

۲- پس از دریافت کامل image می توان با دستور زیر لیست Image های موجود در سیستم خود را ببینید

#### docker images

REPOSITORY	TAG	IMAGE ID	CREATED	SIZE
ubuntu-hadoop	latest	404a3f5d032a	2 weeks ago	1.02 GB
ubuntu	latest	4187f8fa914a	2 weeks ago	541 MB
hub.elastico.io/library/ubuntu	latest	747cb2d60bbe	2 months ago	122 MB
hadoop-img	latest	d6773739675e	2 months ago	5.58 GB
docker.loc:5000/server saeed@saeed-X550CC:~\$	1.0-g	09509117d4e3	6 months ago	1.27 GB

#### شکل ۵-۵

۳- برای ایجاد یک کانتینر(container) داکر از دستور زیر به همراه آرگومان های ورودی آن استفاده می کنیم

docker run -it -v somewhere/:/somewhere --net=host -p port-number:port-number --name test docker-image

در آن محل قرارگیری کانتینر، شماره پورت متناظر با آن، اسم آن و image مورد استفاده باید مشخص شود. برای اینکه کانتینر ایجاد شده به نت سیستم میزبان دسترسی داشته باشد از آرگومان زیر استفاده می کنیم

--net=host

۴- برای مشاهده لیست تمام کانتینر های موجود در سیستم از دستور زیر استفاده می کنیم:

#### docker ps -a

ONTAINER ID	IMAGE	COMMAND	CREATED	STATUS	PORTS	NAMES
80aa7e94668	ubuntu	"/bin/bash"	2 weeks ago	Exited (0) 2 weeks ago		hive
4710cac73bc	ubuntu	"/bin/bash"	2 weeks ago	Exited (0) 2 weeks ago		hbase
c1c43ba0c4c	ubuntu	"/bin/bash"	2 weeks ago	Exited (0) 2 weeks ago		hadoop
c475c824cc4	hub.elastico.io/library/ubuntu	"/bin/bash"	3 weeks ago	Exited (0) 3 weeks ago		spark
8b40c444b45	docker.loc:5000/server:1.0-g	"/bin/bash"	3 months ago	Exited (0) 2 weeks ago		coder
aeed@saeed-X550CC	:~S					

#### شکل ۶-۵

برای مشاهده کانتینرهای فعال از دستور زیر استفاده می کنیم:

#### docker ps

ONTAINER ID	IMAGE	COMMAND	CREATED	STATUS	PORTS	NAMES
ec1c43ba0c4c	ubuntu	"/bin/bash"	2 weeks ago	Up 3 seconds		hadoop

#### شکل ۷-۵

۵- برای فعال کردن یک کانتینر از دستور زیر استفاده می کنیم

docker start hadoop

۶- برای وارد شدن به محیط کانتینر از دستور زیر استفاده می کنیم

docker attach hadoop

۷- برای غیر فعال کردن کانتینر از دستور exit در داخل کانتینر و یا دستور stop در خارج از آن می شود استفاده کرد.

فصل ۶

آپاچی هدوپ APACHE HADOOP

#### 1-9 معرفی

هدوپ یک ابزار متنباز از بنیاد نرمافزار آپاچی است. پروژه متنباز به این معنا است که بدون محدودیت در دسترس است و حتی کد منبع آن نیز طبق نیاز میتواند تغییر داده شود. اگر یک قابلیت خاص نمیتواند نیاز شما را برآورده کند، میتوانید آن را بر اساس نیاز خود تغییر دهید. بسیاری از کدهای هدوپ توسط یاهو، آیبیام، فیسبوک و کلودرا نوشته شده است.

این ابزار یک چارچوب کارآمد برای اجرای برنامه بروی کلاسترها را فراهم میآورد. کلاستر به معنای گروهی از سیستمها است که از طریق یک شبکه ارتباطی به هم متصل شدهاند. هنگامی که مولفه های هدوپ به طور همزمان روی ماشینهای متعدد مستقر می شوند، پردازش و یا رایانش موازی دادهها را برای ما به ارمغان میآورد.

پروژه هدوپ با الهام از دو ابزاری که گوگل از آن برای موتور جستجوی خود استفاده می کند، ایجاد شده است. گوگل در سال ۲۰۰۳ مقاله ای در مورد سیستم فایل توزیع شده خود بنام GFS و مدل برنامه نویسی نگاشت/کاهش منتشر کرد. توسعه هدوپ در ابتدا در پروژه Nutch، که آن زمان Doug Cutting و تیم او مشغول کار روی آن بودند، شکل گرفت؛ اما با توجه به محبوبیت بسیار زیادی که داشت، خیلی زود به یک پروژه ی سطح بالای آپاچی تبدیل شد.

هدوپ یک چارچوب منبعباز است که به زبان جاوا نوشته شده است. اما این بدان معنا نیست که برنامهنویسی برای آن تنها به زبان جاوا امکانپذیر باشد. می توان به زبانهای C ++ برل، پایتون و روبی برنامه های مربوط به این سکو را توسعه داد. اما اگر بدنبال استفاده از تمام خصوصیات توسعه داده شده در هدوپ هستید و یا نیاز است که در سطوح پایین نیز کنترلی بروی کد خود داشته باشید، توصیه می شود از زبان جاوا برای توسعه برنامه خود استفاده کنید.

یکی از ویزگی های دیگر پروژه هدوپ این است که این ابزار حجم انبوه دادهها را در شبکهای از سیستمهای سختافزاری معمولی را به طور کارآمد پردازش می کند. هدوپ به منظور پردازش حجم انبوهی از دادهها ساخته شده است. منظور از سختافزارهای معمولی آن دسته از سختافزارهایی هستند که معمولا در مراکز داده بکار می روند و برای استقرار هدوپ نیاز به یک سخت افزار خاص منظوره نیستیم. در نتیجه هدوپ نیز بسیار به صرفه است.

هدوپ می تواند روی یک تک دستگاه (حالت شبه توزیع شده) نصب شود، اما توانایی واقعی هدوپ در کلاستر یا شبکهای از دستگاهها همراه است و می تواند با قابلیت اطمینان بالا بروی کلاستری با هزاران ماشین در حال کار اجرا شود.

هدوپ دارای سه بخش کلیدی است: سیستم فایل توزیع شده هدوپ (HDFS)، چهارچوب برنامه نویسی نگاشت/کاهش و ابزار مدیریت منابع Yarn.

#### ٢-۶ چرا هدوپ؟

هدوپ نه تنها یک سیستم توزیع شده ذخیره سازی داده است بلکه علاوه بر آن یک سکوی پردازش داده نیز در اختیار ما میگذارد. همچنین هدوپ مقیاس پذیر است (سیستمهای بیشتر میتوانند بدون توقف فرایند اضافه شوند)، تحمل پذیر در مقابل خطا است (حتی اگر یکی از سیستمها دچار مشکل شود، پردازش دیتا میتواند توسط سیستم دیگر انجام شود) و متن باز است (در صورت نیاز کد منبع میتواند تغییر داده شود).

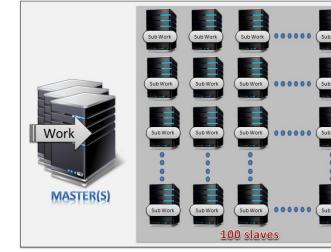
برخی از خصوصیاتی که باعث شده تا هدوپ به عنوان یک ابزار محبوب برای محیط های کلان داده مطرح شود، عبارتند از :

- ◆ انعطاف پذیری در ذخیره سازی داده ها و امکان ذخیره سازی داده ها به هر نوع فرمت اعم از ساختیافته، نیمه
   ساختیافته و بدون ساختار. در واقع در هنگام ذخیرهسازی داده محدود به نوع خاصی نیستیم.
- ♦ انجام پردازشهای پیچیده توسط موتور پردازشی نگاشت/کاهش و توزیع آنها بین ماشینهای کلاستر. در سکوی هدوپ کدهای برنامه به سمت دادهها ارسال میشوند در مقابل آنکه دادهها به سمت برنامه درحال اجرا ارسال شوند. این موضوع باعث استفاده بهینه از پهنای باند کلاستر شده و از ایجاد بار اضافی ناشی از انتقال دادهها در بین گرههای کلاستر جلوگیری می کند.
- ♦ از نظر صرفه اقتصادی، همان طور که گفته شده، هدوپ می تواند روی یک دستگاه معمولی نصب شود. جدا از این موضوع، برخورداری از ویژگی متن باز بودن، آن را در برابر وابستگی به فروشنده حفظ می کند.

#### ۳-۶ معماری هدوپ

هدوپ به سبک Master/Slave کار می کند. در کلاستر هدوپ یک گره Master وجود دارد و تعداد زیادی گره کند که این تعداد می تواند تا هزاران گره نیز ادامه پیدا کند. گره Master، گرههای Slave را مدیریت، حفظ و کنترل می کند در حالی که گرههای Slave، مولفههای واقعی انجام کار هستند.

گره Master، فقط فرادادهها (دادههای درباره داده) را ذخیره می کند در حالی که Slaveها گرههایی هستند که دادهها را ذخیره می کنند. ذخیرهسازی داده بین کلاستر توزیع می شود. کارخواه یا کلاینت برای انجام هر کار به گره Master متصل خضیره می کنند. ذخیرهسازی داده بین کلاستر توزیع می شود.





**6-1** شکل

۴-۶ سیستم فایل توزیع شده هدوپ (HDFS)

HDFS یک سیستم فایل توزیع شده است که امکان ذخیرهسازی در هدوپ را به یک شیوه توزیع شده فراهم می آورد.

در گره Master یک سرویس به نام NameNode اجرا می شود. همچنین بروی همه گرههای Slave سرویسی به نام NameNode اجرا می شوند. NameNode فراداده ها را ذخیره و هنگامی که گرههای داده، دیتاها را ذخیره می کنند و وظیفه واقعی را انجام می دهند، آنها را مدیریت می کند.

HDFS یک سیستم فایل بسیار تحمل پذیر، توزیع شده، قابل اعتماد و مقیاس پذیر برای ذخیره دادهها است. در سیستم فایل توزیع شده هدوپ اطلاعات بیشتری در مورد خصوصیات HDFS وجود دارد.

HDFS به منظور پردازش و کنترل حجم انبوه دادهها ساخته شده است. اندازه فایلهای مورد انتظار می تواند بین محدوده گیگابایت تا ترابایت باشد. در سیستمفایل HDFS، مشابه اکثر سیستمفایلها، از مفهوم بلاک در هنگام ذخیرهسازی دادهها استفاده می شود و یک فایل به چند بلاک (به طور پیش فرض ۱۲۸ مگابایت) تقسیم و بین گرههای متعدد ذخیره می شود. همچنین به منظور فراهم قابلیت دسترس پذیری بالا از مکانیسم تکرار دادهها استفاده می شود. به همین دلیل بلاکهای حاصل از یک فایل داده نیز بر اساس هر عامل تکرار (عامل تکرار پیش فرض ۳) تکرار و در گرههای مختلف ذخیره می گردند. این عمل باعث می شود با ایجاد مشکل در یک گره نیز دادهها از دست نروند. بنابراین برای مثال فایلی با حجم ۶۴۰ مگابایت، به ۵ بلاک ۱۲۸ مگابایتی شکسته خواهد شد و هریک از بلاکها در سه گره ذخیره می شوند (اگر از مقدار پیش فرض استفاده شده باشد).

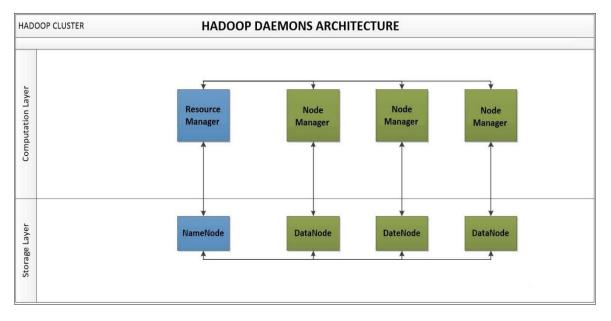
#### ۵-۶ موتور پردازش نگاشت/کاهش

نگاشت/کاهش یک مدل برنامهنویسی شناخته شده برای پردازش حجم زیاد داده از طریق تقسیم کار به مجموعهای از کارهای مستقل و اجرای آن بروی گرههای کلاستر، طراحی شده است. در این مدل کاربر با پیادهسازی توابع نگاشت و کاهش الگوریتم مورد نظر خود را پیاده سازی می کند. علاوه بر این، نگاشت/کاهش موتور پردازشی هدوپ نیز است و از آنجا که انتقال حجم انبوه دادهها پر هزینه است، پردازش را به سمت دادهها ارسال می کند. این موتور پردازشی امکان مقیاس پذیری گسترده میان صدها یا هزاران گره در یک کلاستر هدوپ را ارائه می کند و با توجه به اینکه دادهها به شیوهای توزیعی در HDFS ذخیره می شوند، این عمل شرایطی فراهم می آورد تا نگاشت/کاهش پردازش موازی را در بین گره های یک کلاستر محقق کند.

#### ۶-۶ سرویس مدیریت منابع Yarn

ابزار مدیریت منابع آپاچی Yarn لایه مدیریت منابع هدوپ است. در کلاستر چند گرهای، کنترل، تخصیص و انتشار منابع (پردازنده، حافظه، دیسک) بسیار پیچیده میشود. Yarn به صورت کاملاً کارآمد منابع را مدیریت کرده و با توجه به درخواست برنامهها منابع موردنیاز را با آنها تخصیص میدهد.

در گره Master سرویس ResourceManager و در گرههای Slave نیز سرویس NodeManager اجرا می شود.



شکل ۲-۶

#### ۷-۶ سرویس های هدوپ

۴ سرویس زیر، سرویسهایی هستند که برای استقرار هدوپ بروی یک کلاستر به اجرا در میآیند. سرویسها پردازشهایی هستند که در پسزمینه اجرا می گردند و به درخواستهای رسیده به سمت آنها پاسخ میدهند.

نام سرویس	گره	توضيح
NameNode	Master	- استقرار HDFS
DataNode	Slaves	TIDI 3
ResourceManager	Master	استقرار Yarn
NodeManager	Slaves	

شکل ۳-۶

به منظور راهاندازی هدوپ، چهار سرویس اشاره شده در بالا حتما باید اجرا شوند. اما علاوه بر این سرویسها، سرویسهایی نظیر Job HistoryServer ،Standby NameNode ،NameNode Secondray و غیره می توانند وجود داشته باشند که هریک وظایفی دارند که بنا بر نیاز می توانند مورد استفاده قرار بگیرند.

۸-۶ مراحل پردازش داده ها توسط هدوپ

اگر بخواهیم مراحل پردازش دادهها توسط هدوپ را بطور خلاصه بررسی کنیم، میتوان به مراحل زیر اشاره کرد:

- مرحله ۱ در ابتدا دادههای مورد نیاز برنامه بروی سیستم فایل HDFS قرار می گیرند. دادههای ورودی به بلوکهایی
   با حجم پیش فرض شکسته شده و در گرههای مختلف و با تعداد تکرار مشخص شده ذخیره می شوند.
- ♦ مرحله ۲ برنامه توسعه داده شده کاربر از طریق ابزار مدیرت منابع Yarn بروی کلاستر توزیع شده و اجرا می
   شود.
  - ♦ مرحله ۳ زمانی که کار پردازش پردازش دادهها به اتمام رسید، خروجی برنامه بروی HDFS نوشته میشود.

## فصل ۷

# طریقه نصب هدوپ در اوبونتو

```
١−٧ مراحل نصب
```

برای نصب هدوپ، ترمینال اوبونتو را باز کرده و دستورات زیر را به ترتیب اجرا می کنیم:

١-نصب جاوا

sudo apt-get update

sudo apt-get install default-jdk

۲-افزودن کاربر اختصاصی هدوپ

sudo addgroup hadoop

sudo adduser –ingroup hadoop hduser

۳-نصب ssh

sudo apt-get install ssh

which ssh

which sshd

۴-ساخت و نصب گواهی های ssh

su hduser

ssh-keygen –t rsa –P ""

cat \$HOME/.ssh/id\_rsa.pub >> \$HOME/.ssh/auth orized\_keys

۵–نصب هدوپ

wget <a href="http://mirrors.sonic.net/apache/hadoop/common/hadoop-7,v,f/hadoop-7,v

tar xvzf hadoop-۲,۷,۴.tar.gz

sudo mv \* /usr/local/hadoop

su saeed

sudo adduser hduser sudo

sudo su hduser

sudo mv \* /usr/local/hadoop

sudo chown -R hduser:hadoop /usr/local/hadoop

۶-تنظیم کردن فایل های پیکربندی

فایل های زیر نیازمند ویرایش هستند:

~/.bashrc

/usr/local/hadoop/etc/hadoop/hadoop-env.sh

/usr/local/hadoop/etc/hadoop/core-site.xml

/usr/local/hadoop/etc/hadoop/mapred-site.xml.template

/usr/local/hadoop/etc/hadoop/hdfs-site.xml

دستور زیر را وارد می کنیم:

update-alternatives --config java

حال فایل هایی که اشاره شد را به صورت زیر تغییر می دهیم:

۱- فایل bashrc را با دستور vi ~/.bashrc باز کرده و کدهای زیر را به انتهای آن اضافه می کنیم:

#HADOOP VARIABLES START

export JAVA\_HOME=/usr/lib/jvm/java-\lambda-openjdk-amdff

export HADOOP\_INSTALL=/usr/local/hadoop

export PATH=\$PATH:\$HADOOP\_INSTALL/bin

export PATH=\$PATH:\$HADOOP\_INSTALL/sbin

export HADOOP\_MAPRED\_HOME=\$HADOOP\_INSTALL

export HADOOP\_COMMON\_HOME=\$HADOOP\_INSTALL

export HADOOP\_HDFS\_HOME=\$HADOOP\_INSTALL

export YARN\_HOME=\$HADOOP\_INSTALL

```
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_INSTALL/lib/native
export HADOOP_OPTS="-Djava.library.path=$HADOOP_INSTALL/lib"
#HADOOP VARIABLES END
```

سپس فایل را بسته و برای اعمال تنظیمات دستور زیر را اجرا می کنیم:

source ~/.bashrc

۲- فایل hadoop-env.sh را با دستور usr/local/hadoop/etc/hadoop/hadoop-env.sh/ vi باز کرده و تغییر زیر را اعمال می کنیم:

export JAVA\_HOME=/usr/lib/jvm/java-\u03b4-openjdk-amd\u03b4\u03b4

۳- برای فایل core-site.xml ابتدا دستورات زیر را اجرا می کنیم:

sudo mkdir -p /app/hadoop/tmp

sudo chown hduser:hadoop/app/hadoop/tmp

و سپس تغییرات آن را به صورت زیر با دستور usr/local/hadoop/etc/hadoop/core-site.xml/ vi اعمال می کنیم:

<configuration>

cproperty>

<name>hadoop.tmp.dir</name>

<value>/app/hadoop/tmp</value>

<description>A base for other temporary directories.</description>

cproperty>

<name>fs.default.name</name>

<value>hdfs://localhost:۵۴٣١٠</value>

<description>The name of the default file system. A URI whose

scheme and authority determine the FileSystem implementation. The uri's scheme determines the config property (fs.SCHEME.impl) naming the FileSystem implementation class. The uri's authority is used to determine the host, port, etc. for a filesystem.</description> </configuration> ۴- برای فایل بعدی ابتدا دستور زیر را اجرا می کنیم: cp/usr/local/hadoop/etc/hadoop/mapred-site.xml.template /usr/local/hadoop/etc/hadoop/mapred-site.xml سيس تغييرات زير را لحاظ مي كنيم: <configuration> cproperty> <name>mapred.job.tracker</name> <value>localhost: 45711</value> <description>The host and port that the MapReduce job tracker runs at. If "local", then jobs are run in-process as a single map and reduce task. </description> </configuration> ۵- برای فایل hdfs-site.xml به صورت زیر عمل می کنیم: sudo mkdir -p /usr/local/hadoop\_store/hdfs/namenode

sudo mkdir -p /usr/local/hadoop\_store/hdfs/datanode

sudo chown -R hduser:hadoop /usr/local/hadoop\_store

vi /usr/local/hadoop/etc/hadoop/hdfs-site.xml

و کد های زیر را در آن جای گذاری می کنیم:

```
<configuration>
cproperty>
<name>dfs.replication</name>
<value> \ </value>
<description>Default block replication.
The actual number of replications can be specified when the file is created.
The default is used if replication is not specified in create time.
</description>
cproperty>
<name>dfs.namenode.name.dir</name>
<value>file:/usr/local/hadoop_store/hdfs/namenode</value>
cproperty>
<name>dfs.datanode.data.dir</name>
<value>file:/usr/local/hadoop_store/hdfs/datanode</value>
</configuration>
                             یس از انجام تغییرات، فایل سیستم هدوب را با دستور زیر فرمت کرده:
```

hadoop namenode -format

و در نهایت با دستور زیر هدوپ را اجرا می کنیم:

/usr/local/hadoop/sbin\$ start-all.sh

برای اطمینان از صحت عملکرد آن دستور زیر را اجرا می کنیم:

/usr/local/hadoop/sbin\$ jps

اگر خروجی تولید شده مانند زیر باشد، هدوپ به درستی اجرا شده است:

9.79 NodeManager

YTFA NameNode

9799 Jps

AAAY ResourceManager

۷۵۰۷ DataNode

برای متوقف کردن هدوپ می توان از دستور زیر استفاده کرد:

/usr/local/hadoop/sbin\$ stop-all.sh

۷-۲ اجرای مثال Word Count با هدوپ

یک فایل جاوا با نام WordCount ایجاد کرده و کد زیر را درون آن می نویسیم:

import java.io.IOException;

import java.util.StringTokenizer;

import org.apache.hadoop.conf.Configuration;

import org.apache.hadoop.fs.Path;

import org.apache.hadoop.io.IntWritable;

import org.apache.hadoop.io.Text;

import org.apache.hadoop.mapreduce.Job;

```
import org.apache.hadoop.mapreduce.Mapper;
import org.apache.hadoop.mapreduce.Reducer;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
public class WordCount {
  public static class TokenizerMapper extends Mapper<Object, Text, Text,
IntWritable>{
    private final static IntWritable one = new IntWritable(\);
    private Text word = new Text();
    public void map(Object key, Text value, Context context) throws IOException,
InterruptedException {
       StringTokenizer itr = new StringTokenizer(value.toString());
       while (itr.hasMoreTokens()) {
         word.set(itr.nextToken());
         context.write(word, one);
       }
    }
  }
  public static class IntSumReducer extends
Reducer<Text,IntWritable,Text,IntWritable> {
    private IntWritable result = new IntWritable();
```

```
public void reduce(Text key, Iterable<IntWritable> values, Context context)
throws IOException, InterruptedException {
       int sum = \cdot;
       for (IntWritable val: values) {
         sum += val.get();
       }
       result.set(sum);
       context.write(key, result);
     }
  }
  public static void main(String[] args) throws Exception {
     Configuration conf = new Configuration();
     Job job = Job.getInstance(conf, "word count");
    job.setJarByClass(WordCount.class);
    job.setMapperClass(TokenizerMapper.class);
    job.setCombinerClass(IntSumReducer.class);
    job.setReducerClass(IntSumReducer.class);
    job.setOutputKeyClass(Text.class);
    job.setOutputValueClass(IntWritable.class);
     FileInputFormat.addInputPath(job, new Path(args[·]));
     FileOutputFormat.setOutputPath(job, new Path(args[v]));
     System.exit(job.waitForCompletion(true) ? · : \);
```

```
}
```

با دستور زیر آن را کامپایل کرده و .class آن را می سازیم:

bin/hadoop com.sun.tools.javac.Main WordCount.java

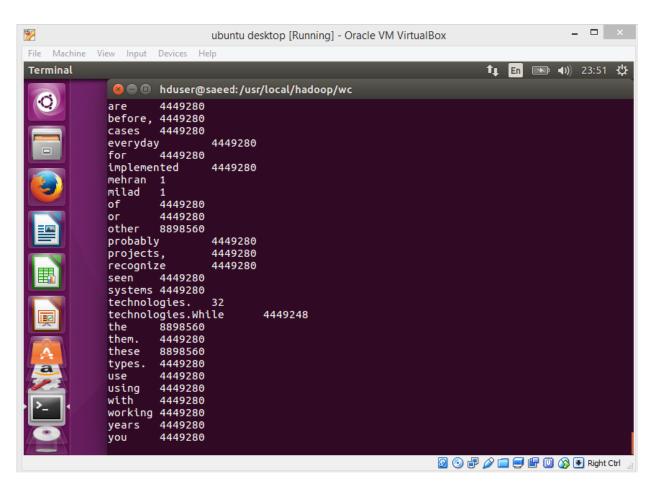
سپس با دستور زیر فایل .jar آن را تولید می کنیم:

jar cf wc.jar WordCount\*.class

پوشه ای با نام input می سازیم و تعدادی فایل متنی جهت شمارش تعداد کلمات آن درون آن قرار می دهیم.

bin/hadoop jar wc.jar WordCount /user/saeed/wordcount/output /user/saeed/wordcount/input

پس از اجرای دستور فوق، فایلی در پوشه output ایجاد شده و نتیجه شمارش را ذخیره کرده است.



شکل ۱-۷

۳-۷ استفاده از ماشین مجازی هدوپ

روش آسان برای داشتن هدوپ، استفاده از بسته های آماده هدوپ است که توسط شرکت های مختلفی تهیه شده اند. بسته های آماده هدوپ را شرکت های مختلفی چه به صورت بسته کامل و چه به صورت گزینشی ارائه می کنند. این شرکت ها عبارتند است از:

- IBM ♦
- Cloudera ◆
- Hortonworks ♦

هر کدام از این شرکت ها بسته های آماده ای را به صورت رایگان فراهم می کنند که هرچند دارای حجم بالایی هستند ولی می توانند توسط نرم افزارهای مجازی سازی به صورت مستقل اجرا شوند و همچنین این بسته ها عموما دارای امکانات بالاتری نسبت به بسته عمومی هدوپ است. این بسته های آماده حتی شامل واسط های مدیریتی گرافیکی است که توانایی کار با هدوپ را آسانتر می کند. نکته دیگر این است که این بسته ها شامل زیرپروژه های بیشتری نسبت به بسته عمومی می باشند.

برای استفاده از این بسته ها کافی است به لینک های زیر مراجعه کنید و بسته مربوط به نرم افزار مجازی سازی خود را بارگیری نمایید و اجرا کنید:

- ♦ بسته ماشین مجازی اختصاصی مرجع هدوپ ایران
  - Cloudera QuickStart VMs •
- InfoSphere BigInsights Quick Start Edition
  - Hortonworks Data Platform ◆

به دلیل وجود تحریم ها و ممنوعیت استفاده ایرانیان، بسته ماشین مجازی مرجع هدوپ ایران را دریافت می کنیم و از آن برای اجرای مثال استفاده می کنیم.

برای دریافت این ماشین مجازی، ابتدا از طریق لینک زیر تصویر آن را دریافت می کنیم:

https://hadoop.ir/box/

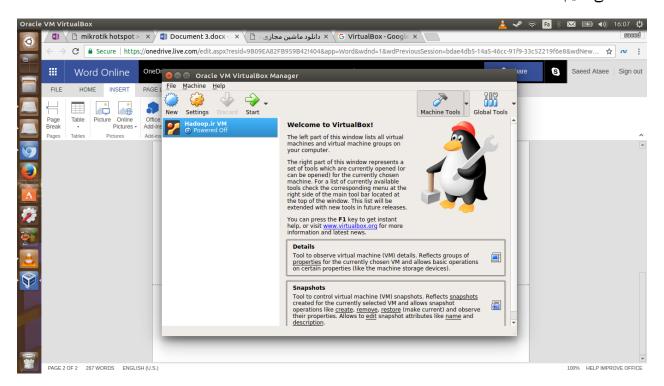
برای اجرای آن از VirtualBox استفاده می کنیم.



## **VirtualBox**

#### شکل ۲-۷

پس از دانلود تصویر، طبق فیلم آموزشی موجود در سایت، تصویر را به VirtualBox اضافه می کنیم و آن را Start می کنیم.



شکل ۳-۷

پس از بالا آمدن کامل ماشین مجازی، دستور زیر را برای مشاهده لیست فایل های هدوپ می زنیم:

hadoop fs -ls

برای اجرای مثال شمارش کلمات به صورت زیر عمل می کنیم.

۱- ایجاد فایل mytest جهت قرار دادن فایل های مثال در آن با دستور زیر:

hadoop fs -mkdir mytest

۲- ایجاد فایل input برای قرارگیری فایل های ورودی در آن:

hadoop fs -mkdir mytest/input

۳- ایجاد فایل ورودی جهت تست با دستور زیر:

nano test.txt

در فایل وارد شده ورودی دلخواه را وارد می کنیم و آن را ذخیره می کنیم و می بندیم.

۴- فایل تست ایجاد شده را در به قسمت فایل های ورودی منتقل می کنیم:

hadoop fs -put test.txt mytest/input

- برای اجرای مثال به مسیر زیر می رویم:

cd /opt/hadoop/share/hadoop/mapreduce

۶- برای اجرای مثال دستور زیر را وارد می کنیم:

hadoop jar hadoop-mapreduce-examples-۲,۷,۱.jar wordcount mytest/input mytest/output

۷- پس از اجرای کامل دستور فوق، می توان خروجی ایجاد شده را در مسیر mytest/output مشاهده کرد:

hadoop fs —ls mytest/output

۸- فایل part-r-۰۰۰۰ نتیجه را ذخیره کرده است.

hadoop fs -cat mytest/output/part-r-····

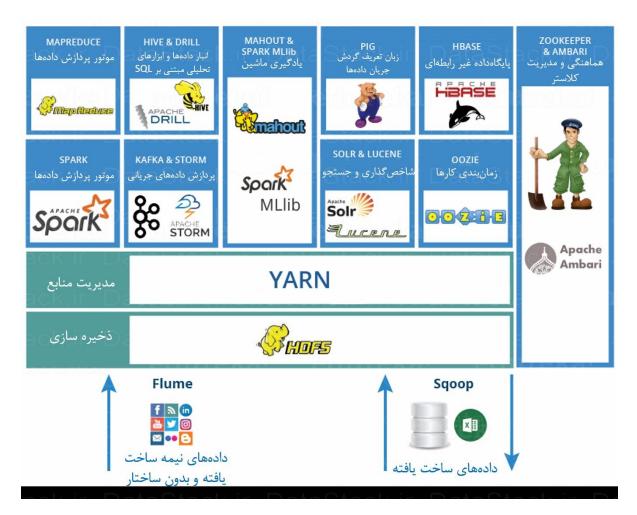


شکل ۴-۷

فصل ۸

اكوسيستم هدوپ

اکوسیستم هدوپ سکویی است که با مجموعه ابزارهایی که در اختیار دارد می تواند به حل مشکلات کلان دادهها کمک کند. هدوپ را می توان به عنوان مجموعهای در نظر بگیرید که دربر دارنده ی تعدادی از سرویسهای (جمع آوری، ذخیره، تجزیه و تحلیل و نگه داری) کار با داده در درون خود می باشد. در ادامه بررسی مختصری از نحوه ی عملکرد سرویسهای آن، هم به مطور مجزا و هم در همکاری با یکدیگر می پردازیم که می توان گفت در مجموع اکوسیستم هدوپ را تشکیل می دهند:



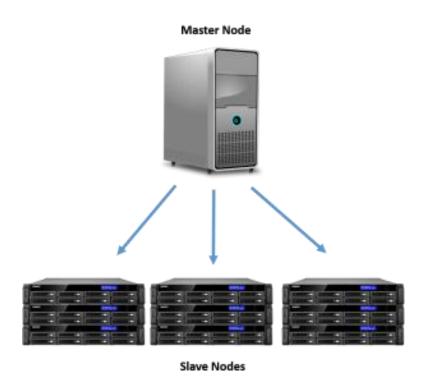
شکل ۱-۸

#### $\mathrm{HDFS}-$ سیستم فایل توزیع شده هدوپ – $\mathrm{A-1}$

سیستم فایل توزیع شده ی هدوپ که عنصر سازنده و زیربنایی هدوپ است و به عبارتی می توان از آن به عنوان ستون اصلی اکوسیستم هدوپ یاد کرد. این فایل سیستم امکان ذخیره سازی انواع مختلفی از مجموعه ی داده ها (داده های ساختاریافته، بدون ساختار و نیمه ساختیافته) را فراهم می آورد. همچنین HDFS، مفهومی انتزاعی پیرامون منابع کلاستر ایجاد می کند، که این موضوع به ما این اجازه را می دهد تا آن را به عنوان یک واحد مجزا در نظر بگیریم. برای این منظور، HDFS داده ها

را در سرتاسر کلاستر در گرههای مختلف و فرادادههای داده را در یک گره نگهداری می کند. HDFS دو عنصر سازندهی Datanode و Namenode

- ♦ Namenode گرهی اصلی در سیستم فایل HDFS است و فرادادههای مربوط به دادهها را ذخیره می کند. درست مانند یک فایل ثبت رخداد ، دربر دارندهی فرادادهها است و به عبارتی می توان آن را به عنوان جدول محتویات سیستم فایل تعبیر کرد. بنابراین، نیاز به فضای ذخیرهسازی کمتر و منابع محاسباتی (مخصوصا RAM) بالا دارد.
- ♦ از طرفی دیگر، تمام دادههای شما در Datanodes ذخیره می گردد و به همین خاطر نیاز به منابع ذخیرهسازی بیشتری دارد. این Datanode ها، سخت افزار ارزان قیمت در یک محیط توزیع شده هستند (شاید چیزی نظیر لپتاپها و کامپیوترهای شخصی شما). به همین علت است که راهکارهای ارائه شده توسط هدوپ بسیار مقرون به صرفه هستند.



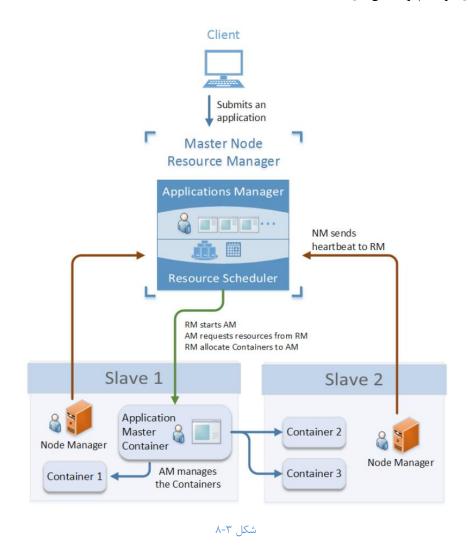
شکل ۲-۸

YARN چهارچوب مدیریت منابع

YARN را به عنوان مغز اکوسیستم هدوپ در نظر بگیرید. این ابزار تمامی فعالیتهای پردازشی شما را به وسیلهی تخصیص منابع و برنامهریزی، انجام میدهد. YARN دو جزء اصلی دارد: ResourceManager و NodeManager:

ResourceManager همان گرهی اصلی در بخش پردازش است.

- ♦ درخواستهای پردازشی را دریافت می کند و سپس هر بخش از درخواستها را به NodeManager متناسب با
   هر درخواست ارسال می کند (جایی که پردازش حقیقی رخ می دهد).
- ♦ NodeManager ها بر روی گرههای Slave نصب می شوند. NodeManager ها مسئول اجرای وظیفه بر روی هر کدام از ماشینهای Slave هستند.



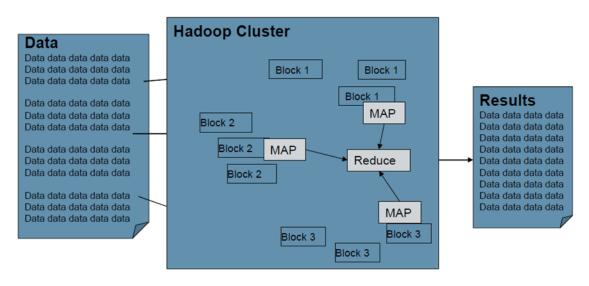
مولفه RecourseManager نيز از دو جزء تشكيل شده: Schedulers و RecourseManager

Scheduler بر اساس منابع مورد نیاز برنامه و براساس پیکربندی کلاستر، هنگام تخصیص منابع الگوریتمهای زمانبندی را اجرا و براساس نتایج آن منابع را تخصیص میدهد. ApplicationsManager نیز در هنگام قبول یک کار جدید، بررسیهای لازم برای پذیرفته شدن کار در کلاستر را انجام میدهد. اینکه آیا منابع کلاستر پاسخگوی نیاز کار باشد، شماره

کار جدید قبلا در کلاستر نباشد و بررسیهای دیگر را انجام داده و درصورت پذیرفته شدن کار، آن را به مولفه Scheduler تحویل میدهد.

#### ۸-۳ موتور پردازش MapReduce

نگاشت/کاهش ابزار پردازش در اکوسیستم هدوپ است، که یک لایه پردازشی منطقی ارائه می دهد. به عبارت دیگر، نگاشت/کاهش یک چارچوب نرمافزاری است که به نوشتن برنامه هایی کمک می کند، که مجموعه ای داده های عظیم را با استفاده از الگوریتمهای موازی و توزیع شده، در محیط هدوپ پردازش می کنند.



شکل ۴-۸

در یک برنامه ی نگاشت/کاهش، توابع Map() و Reduce()، دو وظیفه ی مجزا دارند:

- ♦ وظیفهی Map فعالیتهایی همچون فیلتر کردن، گروهسازی و ذخیرهسازی است.
- ♦ در حالی که وظیفهی Reduce، جمعآوری و خلاصهسازی نتایجی است که از طریق Map حاصل شده است.
- ♦ در واقع نتایجی که از طریق وظیفه ی Map حاصل شده، یک جفتِ کلید/مقدار (K/V) است، که یک داده ی ورودی برای وظیفه ی Reduce محسوب می شود.

#### ۸-۴ آیاچی ماهوت APACHE MAHOUT

ابزار پرکاربرد دیگر اکوسیستم هدوپ، آپاچی ماهوت میباشد. ماهوت واسطهایی برای ایجاد برنامههای قابل مقیاسپذیر یادگیری ماشین فراهم می کند.



### یادگیری ماشین چیست؟

الگوریتمهای فراگیری ماشینی، اجازه ی ساخت سیستمهای خود-یادگیرنده را به ما میدهند، که بدون آن که نیاز به برنامهریزی مشخصی داشته باشد، تکامل مییابند. بر اساس رفتار کاربر، الگوهای داده و تجربیات گذشته میتوانند در تصمیمات آینده یاری رسان باشند.

#### Mahout چه کاری انجام می دهد؟

پالایش گروهی، خوشهبندی، طبقهبندی و قواعد انجمنی کارهایی است که میتوان توسط Mahout انجام داد:

- پالایش گروهی: Mahout رفتارهای کاربران، الگوهای آنها و ویژگیهایشان را بررسی میکند و بر اساس آن
   پیشبینیهایی انجام میدهد و به کاربران پیشنهاد میدهد. رایج ترین کاربرد آن، استفاده در وبسایتهای تجارت
   الکترونیکی است.
- ◆ طبقهبندی: این روش به طبقهبندی و دستهبندی دادهها به زیر مجموعههایی بر اساس خصوصیاتشان اشاره دارد.
   در واقع در این روش مجموعهای از قوانین بر اساس دادههای موجود (دادههای مجموعه آموزش) ایجاد میشود تا
   بر اساس آن طبقهبندی مناسبی برای موضوع جدید در میان طبقهبندیهای مختلف انجام گیرد. این روش جزء
   روش های یادگیری با نظارت محسوب میشود.
- ♦ **قواعد انجمنی** : قوانین انجمنی روابط و وابستگیهای متقابل بین مجموعه بزرگی از اقلام داده ای را نشان میدهند. پیدا کردن چنین قوانینی میتواند در حوزه های مختلف مورد توجه بوده و کاربردهای متفاوتی داشته

باشد. بعنوان مثال کشف روابط انجمنی بین حجم عظیم تراکنش های کسب و کار میتواند درتشخیص تقلب، در حوزه پزشکی و همچنین در مورد اطلاعات روش بکارگیری وب توسط کاربران مورد استفاده قرار گیرد.

Mahout خط فرمانی برای فراخوانی الگوریتمهای مختلف ارائه می دهد. این ابزار از مجموعه کتابخانه از پیش تعیین شدهای بهره می برد که در حال حاضر شامل الگوریتمهای داخلی متعدد، برای کاربردهای مختلف است.

#### ۵-۸ آپاچی زو کیپر - APACHE ZOOKEEPER

Apache Zookeeper یک ابزار هماهنگ کننده برای سرویسهای در هدوپ است که برای اجرا نیاز به ترکیبی از سرویسهای مختلف سرویسهای مختلف در اکوسیستم هدوپ دارند. Apache Zookeeper نقش یک هماهنگ کننده سرویسهای مختلف در یک محیط توزیع شده را برعهده دارد.



#### شکل ۶-۸

قبل از عرضهی Zookeeper، هماهنگی میان سرویسهای مختلف در اکوسیستم هدوپ بسیار دشوار و زمانبر بود. پیش از آن، سرویسها مشکلات زیادی برای تعامل با مواردی همچون پیکربندی کردن سیستمها همراه با همگام نگه داشتن دادهها داشتند. حتی اگر سرویسها پیکربندی میشدند، تغییر در پیکربندی سرویسها تبدیل به مسئلهای پیچیده میشد و مدیریت آن را دشوار می کرد.

Zookeeper برای حل مشکلات بالا خلق شد. با انجام وظایفی نظیر همگامسازی، حفظ پیکربندی، گروهبندی و نام گذاری، به طور چشم گیری در زمان حل اینگونه مسائل صرفه جویی شد. برخلاف ساده بودن این سرویسها، می توان از آن برای ارائه ی به مطور چشم گیری در زمان حل اینگونه مسائل صرفه جویی شد. برخلاف ساده بودن این سرویسها، می توان از آن برای ارائه ی و Yahoo ،Rackspace و Pay از این سرویس در بسیاری از موارد کاری خود بهره می برند، در نتیجه می توان به ارزش و اهمیت این ابزار پی برد.

فصل ۹

# آپاچی هایو Apache Hive

#### **۱-۹** معرفی

فیسبوک، Hive را برای آن دسته از افرادی طراحی کرده که می توانند به راحتی با SQL کار کنند. در نتیجه، شما با تجربهای نظیر کار با دستورات SQL مشغول کار کردن در اکوسیستم هدوپ هستید. در واقع، Hive یک انبار داده در اکوسیستم هدوپ است که مسئولیت خواندن، نوشتن و مدیریت مجموعه داده های بزرگ را در یک محیط توزیع شده و با استفاده از واسطی مانند SQL، برعهده دارد.



شکل ۱-۹

هایو همه نوع دادههای اولیهی SQL را پشتیبانی می کند. همچنین می توانید برای انجام دادن نیازهای خاص خود، از تابعهای نوشته شده توسط کاربر (UDF) و یا توابع از پیش تعین شده، استفاده کنید.

زبان پرسوجوی Hive Query Language ،Hive یا HQL نامیده می شود، که بسیار مشابه زبان SQL است.

SQL= HQL +Hive

این زبان از دو جزء اصلی تشکیل شده: خط فرمان Hive و درایور JDBC/ODBC

- ♦ رابط خط فرمان Hive، که برای اجرای دستورات HQL مورد استفاده قرار می گیرد.
- ♦ در حالی که درایور پایگاه داده ی جاوا (JDBC) و درایور پایگاه داده ی اشیاء (ODBC)، به منظور ایجاد اتصالی
   از ذخیرهسازهای داده استفاده می شود.

۹-۲ نصب آپاچی Hive بر روی اوبونتو

برای نصب، ورژن مناسب آن را از سایت آپاچی دانلود و سپس مراحل زیر را طی می کنیم

apache-hive-۱,۲,۲- و دریافت فایل <u>http://www-us.apache.org/dist/hive/stable/</u> و دریافت فایل bin.tar.gz

۲- خارج کردن فایل از حالت فشرده با دستور مقابل

> tar -xzvf apache-hive-\,\,\,\-bin.tar.gz

٣- تمامي فايل ها را به مسير مناسبي منتقل مي كنيم

> mkdir /usr/local/hive

> mv apache-hive-1,7,7-bin/\* /usr/local/hive/

۴- فایل bashrc را تغییر داده و کدهای زیر را به انتهای آن اضافه می کنیم

# HIVE HOME PATH

export HIVE\_HOME=/usr/local/hive

export PATH=\$PATH:\$HIVE\_HOME/bin

# END HIVE HOME PATH

می سازیم hdfs می سازیم مربوط به هایو را در

> hadoop fs -mkdir /usr/hive/warehouse

این دایر کتوری برای ذخیره کردن جدول ها و داده های مربوط به هایو خواهد بود.

۶- پوشه tmp را به منظور نگهداری نتایج میانی پردازش می سازیم

> hadoop fs -mkdir /usr/tmp

۷- دسترسی های لازم برای تغییر و نوشتن این فایل ها را ایجاد مے، کنیم

> hadoop fs -chmod g+w /usr/hive/warehouse

> hadoop fs -chmod g+w /usr/tmp

۸- به فایل hive-conf.sh خط زیر را اضافه می کنیم

> nano /usr/local/hive/bin/hive-conf.sh

export HADOOP\_HOME=/usr/local/hadoop

۹- برای اجرای hive و دسترسی به خط فرمان آن از دستور زیر استفاده می کنیم

> hive

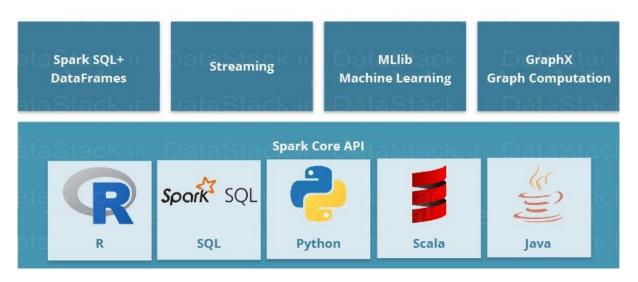
فصل ۱۰

# آپاچی اسپارک APACHE SPARK

#### ۱--۱ معرفی

آپاچی اسپارک چهارچوبی برای تجزیه و تحلیل دادههای دستهای و جریانی در یک محیط محاسباتی توزیع شده است. این ابزار به زبان برنامهنویسی اسکالا نوشته شده و نخست در دانشگاه برکلی کالیفرنیا توسعه یافته است. اسپارک از محاسبات درون حافظهای به منظور افزایش سرعت پردازش دادهها استفاده میکند که در مقایسه با مدل نگاشت/کاهش از کارایی بهتری برخوردار است.

سرعت اسپارک برای پردازش دادههای بزرگ با بهرهوری از محاسبات درون حافظهای و دیگر بهینهسازیها، نزدیک به ۱۰۰ برابر سریع تر از هدوپ در زمانیکه دادهها دورن حافظه جای بگیرند و تا دهها برابر نسبت به زمانی که تمام دادهها در جافظه قرار نگیرند. بنابراین، در مقایسه با MapReduce، قدرت پردازشی بالاتری دارد.



شکل ۱۰-۱

همانطور که مشاهده می کنید، اسپارک با کتابخانههای سطح بالایی ارائه شده است و زبانهای برنامهنویسی Python ،R و مشاهده می کنید، اسپارک به مجموعه سرویسهای Scala و Scala زبانهایی هستند که می توان توسط آن از این ابزار استفاده کرد. ابزار آپاچی اسپارک به مجموعه سرویسهای مختلف، اجازه ی ادغام نمونههایی هم چون کتابخانههای یادگیری ماشین MLib، واسطهای تحلیل دادههای گرافی GraphX، واسطهای تحلیل دادههای رابطهایی Pata Frames + SQL و سرویسهای دادههای جریانی، برای افزایش قابلیتهای خودش می دهد.

#### ۲-۱۰ نصب آپاچی اسپارک بر روی اوبونتو



شکل ۲-۱۰

**١**- جاوا

برای اجرا و نصب اسپارک باید جاوا بر روی ماشین نصب باشد. با استفاده از دستور زیر چک می کنیم جاوا بر روی سیستم نصب هست یا خیر:

Java -version

در صورتی که جاوا نصب نباشد، با دستورات زیر اقدام به نصب آن کنید:

sudo apt-get update

sudo apt-get install default-jdk

```
root@saeed-X550CC:~# java -version
openjdk version "1.8.0_151"
OpenJDK Runtime Environment (build 1.8.0_151-8u151-b12-0ubuntu0.16.04.2-b12)
OpenJDK 64-Bit Server VM (build 25.151-b12, mixed mode)
root@saeed-X550CC:~#
```

شکل ۳-۱۰

scala -۲

پس از نصب جاوا بر روی ماشین، اقدام به نصب scala از طریق دستور زیر می نماییم:

sudo apt-get install scala

برای تست صحت تست دستور scala را برای اجرای آن در ترمینال وارد می کنیم و دستور زیر را وارد می کنیم:

```
println("Hello World")
```

و با دستور زیر، اجرای آن را خاتمه میدهیم:

:q

```
root@saeed-X550CC:~/spark-2.2.0-bin-hadoop2.7/bin# scala
Welcome to Scala version 2.11.6 (OpenJDK 64-Bit Server VM, Java 1.8.0_151).
Type in expressions to have them evaluated.
Type :help for more information.

scala> println("Hello World!")
Hello World!

scala> :q
root@saeed-X550CC:~/spark-2.2.0-bin-hadoop2.7/bin#
```

شکل ۲-۱۰

٣- گيت

برای نصب اسپارک، ابتدا باید ابزار گیت نصب شود. پس از دستور زیر برای نصب آن استفاده می کنیم:

sudo apt-get install git

۴- اسیارک

پس از نصب کامل آن، به صفحه دانلود آپاچی اسپارک به آدرس زیر رفته و ورژن مناسب را دریافت می کنیم:

https://spark.apache.org/downloads.html

یس از اتمام دانلود، فایل را از حالت فشرده خارج می کنیم:

tar xvf spark-Y, , Y-bin-hadoopY, V.tgz

سپس به دایرکتوری bin واقع در اسپارک رفته و فایل زیر را اجرا می کنیم:را می کنیم:

cd /spark-۲,۲,·-bin-hadoop۲,۷/bin

./spark-shell

با اجرای دستور زیر و گرفتن خروجی، از نصب کامل آن بر روی ماشین اطمینان حاصل می نماییم:

println("Spark shell is running")

```
Using Spark's default log4j profile: org/apache/spark/log4j-defaults.properties

Setting default log level to "WARN".

To adjust logging level use sc.settoglevel(newLevel). For SparkR, use setLogLevel(newLevel).

17/11/29 89:45:14 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable 17/11/29 89:45:14 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable 17/11/29 89:45:14 WARN Utils: Your hostname, saeed-XSSOCC resolves to a loopback address: 127.0.1.1; using 172.24.84.133 instead (on interface wlp3s)

17/11/29 89:45:14 WARN Utils: Set SPARK_LOCAL_IP if you need to bind to another address

17/11/29 89:45:45 WARN ObjectStore: Version information not found in metastore. hive.metastore.schema.verification is not enabled so recording the schema version 1.2.0

17/11/29 89:45:44 WARN ObjectStore: Failed to get database default, returning NoSuchObjectException

17/11/29 89:45:44 WARN ObjectStore: Failed to get database global_temp, returning NoSuchObjectException

17/11/29 89:45:49 WARN ObjectStore: Failed to get database global_temp, returning NoSuchObjectException

17/11/29 89:45:49 WARN ObjectStore: Failed to get database global_temp, returning NoSuchObjectException

17/11/29 89:45:49 WARN ObjectStore: Failed to get database global_temp, returning NoSuchObjectException

17/11/29 89:45:49 WARN ObjectStore: Failed to get database global_temp, returning NoSuchObjectException

17/11/29 89:45:49 WARN ObjectStore: Failed to get database global_temp, returning NoSuchObjectException

17/11/29 89:45:49 WARN ObjectStore: Failed to get database global_temp, returning NoSuchObjectException

17/11/29 89:45:49 WARN ObjectStore: Failed to get database global_temp, returning NoSuchObjectException

17/11/29 89:45:49 WARN ObjectStore: Failed to get database global_temp.

17/11/29 89:45:49 WARN ObjectStore: Failed to get database global_temp.

17/11/29 89:45:49 WARN ObjectStore: Failed to get d
```

شکل ۵-۱۰

۳-۱۰ اجرای مثال ۱۰-۳

پس از نصب اسپارک و اجرای آن، مثال شمارش کلمات را اجرا می کنیم. بدین منظور، در shell دستورات زیر را به ترتیب اجرا می کنیم:

import org.apache.spark.SparkContext

import org.apache.spark.SparkContext.\_

val txtFile = "inputFile.txt"

val txtData = sc.textFile(txtFile)

txtData.cache()

برای مشاهده تعداد خط موجود در فایل می توان از دستور زیر استفاده کرد:

txtData.count()

برای نمایش تعداد کلمات موجود در آن از دستورات زیر استفاده می کنیم:

val wcData = txtData.flatMap(l => l.split(" ")).map(word => (word, \)).reduceByKey(\_ + \_)

wcData.collect().foreach(println)

#### خروجی به صورت زیر خواهد بود:

```
saeed@saeed-X550CC: ~

(A,1)
(through,1)
(#,1)
(following,2)
(More,1)
(which,2)
(also,4)
(storage,1)
(should,2)
(fo,2)
(for,12)
(once,1)
("Wseful,1)
(setup,1)
(mesos://,1)
(Maven](http://maven.apache.org/).,1)
(the,24)
(your,1)
(dtferent,1)
(different,1)
(distributions.,1)
(given.,1)
(About,1)
(if,4)
(instructions.,1)
(be,2)
(do,2)
(Tests,1)
(no,1)
(project.,1)
(,/bin/run-example,2)
(programs,,1)
(including,4)
('./btn/run-example,1)
(versions,1)
(versions,1)
(started,1)
(hDFF,1)
(by,1)
(individual,1)
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             🛓 🤶 🖪 🖇 🖂 🕟 🜒 17:09 😃
```

شکل ۲-۱۰

فصل ۱۱

## آپاچی اچبیس APACHE HBASE



شكل ١١-١

1-11 معرفي

HBase پایگاه داده ای توزیع شده، غیر رابطه ای، متن باز و یکی از انواع پایگاه داده های NoSQL محسوب می شود. این بایگاه داده به زبان جاوا نوشته شده و از نوع سطر گسترده می باشد. ایده اولیه آن از محصول BigTable گوگل مدل سازی شده است، که برای سیستمهای ذخیره سازی توزیع شده طراحی شده تا بتواند از عهده ی مجموعه داده های بزرگ برآید. HBase برای زیر ساخت خود از HDFS استفاده می کند و قابلیتهایی نظیر BigTable را فراهم می سازد. به منظور ارتباط با این پایگاه داده علاوه بر کلاینتهای مختلف که برای اکثر زبانهای برنامه نویسی توسعه داده شده اند، می توان از Thrift APIs و Avro ، REST نیز استفاده کرد.

۱۱-۲ نصب آپاچی hbase بر روی اوبونتو

نصب hbase به سه صورت Standalone و Pseudo-Distributed و Fully Distributed امکان پذیر است. نصب در حالت اول هیچ وابستگی به هدوپ ندارد و حالت پیش فرض است و بر روی یک jvm اجرا می شود. حالت شبه توزیع شده آن از سیستم هدوپ تگ گره استفاده می کند و بر روی HDFS هدوپ اجرا می شود. حالت توزیع شده آن بر روی هدوپ به صورت چند گره اجرا می شود و به شدت برای محیط production توصیه می شود.

در اینجا ما به نصب حالت اول آن می پردازیم. بدین منظور، ابتدا ورژن مناسب آن را از سایت آپاچی دانلود می کنیم.

hbase-۱,۲,۶- و دریافت فایل <u>http://www-eu.apache.org/dist/hbase/stable/</u> و دریافت فایل <u>bin.tar.gz</u>

۲- خارج کردن فایل از حالت فشرده با دستور زیر

> tar xvzf hbase-1,7,8-bin.tar.gz

۳-انتقال تمامی فایل ها به مسیر مناسب برای اجرای آن

> mv hbase-1,7,8/\* /usr/local/hbase/

۴- تغییر فایل hbase-env.sh و اصلاح مسیر جاوا در آن

> nano hbase-env.sh

و تغيير أن به حالت زير JAVA\_HOME يافتن مقدار

> export JAVA\_HOME=\$(readlink -f /usr/bin/java | sed "s:bin/java::")

```
۵- فایل bashrc نیز باید تغییر کند و آدرس bbase را در آن درج کنیم
> nano ~/.bashrc
                                                         و موارد زیر را به انتهای آن اضافه می کنیم
# HBASE PATH
export HBASE_HOME=/usr/local/hbase
export PATH=$PATH:$HBASE_HOME/bin
                                         و از دستور زیر برای اعمال تغییرات در سیستم استفاده می کنیم
> source ~/.bashrc
                                               ۶-فایل hbase-site.xml باید به صورت زیر تغییر کند
> mkdir -p /usr/local/hbase_store/hbase
> mkdir -p /usr/local/hbase_store/zookeeper
> nano hbase-site.xml
                                                     و محتوای فایل را به صورت زیر تغییر می دهیم:
<configuration>
cproperty>
<name>hbase.rootdir</name>
<value>file:///usr/local/hbase_store/hbase</value>
cproperty>
<name>hbase.zookeeper.property.dataDir</name>
<value>/usr/local/hbase_store/zookeeper</value>
</configuration>
```

۷- در گام بعدی چک می کنیم موارد زیر حتما در فایل /etc/hosts به صورت زیروجود داشته باشد

۱۲۷, · , · , localhost

۱۲۷...۱ saeed-X۵۵.CC

۸- اکنون hbase را با دستور زیر اجرا می کنیم

> cd /usr/local/hbase/bin

> start-hbase.sh

پس از اجرا شدن دستور فوق، با زدن دستور jps می توان از صحت اجرای آن اطمینان حاصل کرد

```
root@saeed-X550CC:/usr/local/hbase/bin# start-hbase.sh
starting master, logging to /usr/local/hbase/logs/hbase--master-saeed-X550CC.out
OpenJDK 64-Bit Server VM warning: ignoring option PermSize=128m; support was removed in 8.0
OpenJDK 64-Bit Server VM warning: ignoring option MaxPermSize=128m; support was removed in 8.0
root@saeed-X550CC:/usr/local/hbase/bin# jps
348 Jps
94 HMaster
root@saeed-X550CC:/usr/local/hbase/bin#
```

#### شکل ۲-۱۱

۹- اجرای shell مربوط به bbase از طریق دستور زیر امکان پذیر است که امکان اجرای دستورات مختلف به bbase را برای ما مقدر می کند

> hbase shell

```
root@saeed-X550CC:/usr/local/hbase/bin# hbase shell
2017-12-04 09:58:04,447 WARN [main] util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
HBase Shell; enter 'help<RETURN>' for list of supported commands.
Type "exit-RETURN>" to leave the HBase Shell
Version 1.2.6, rUnknown, Mon May 29 02:25:32 CDT 2017
hbase(main):001:0> status
1 active master, 0 backup masters, 1 servers, 0 dead, 2.0000 average load
hbase(main):002:0>
```

شکل ۱۱-۳

### منابع و ماخذ

- ۱- وبسایت فارسی داکر Docker.ir
- ۲- مخزن ایرانی تصاویر داکر Elastic.io
- ۳- وبسایت رسمی آپاچی Apache.org
- https://hadoop.apache.org/ .a
  - https://hive.apache.org/ .b
  - http://spark.apache.org/
  - http://hbase.apache.org/ .d
- http://mahout.apache.org/ .e
- http://zookeeper.apache.org .f
  - ۴- ویکی پدیا
- https://en.wikipedia.org/wiki/Big\_data .a
- https://en.wikipedia.org/wiki/Docker\_(software) .b
  - https://en.wikipedia.org/wiki/Apache\_hive .c
  - https://en.wikipedia.org/wiki/Apache\_Spark
- https://www.ibm.com/developerworks/library/bd-yarn-intro 4
  - https://www.infoq.com/articles/apache-spark-introduction -9
    - ۷- مرجع آموزش و ارزیابی زبانهای برنامه نویسی Tutiran.com
      - ۸- مرجع هدوب ایران Hadoop.ir
      - 9- وسایت دیتا استک Datastack.ir
    - http://www.guruqq.com/hbase-installation-guide.html -1.
- http://www.guruqq.com/hbase-limitations-advantage-problems.html 11
- http://www.bogotobogo.com/Hadoop/BigData\_hadoop\_Install\_on\_ubuntu\_single\_\_-\rangle\_ node\_cluster.php
  - ۱۳- کتاب تحلیلهای عظیم داده: نقشه راه پیاده سازی، فناوری و ابزارها دیوید لوشین ترجمه سعید روحانی، سمیه حسینی
    - ۱۴- کتاب اصول دادههای بزرگ: مفاهیم، پیشرانها و تکنیکها توماس ارل ترجمه حسن رشیدی